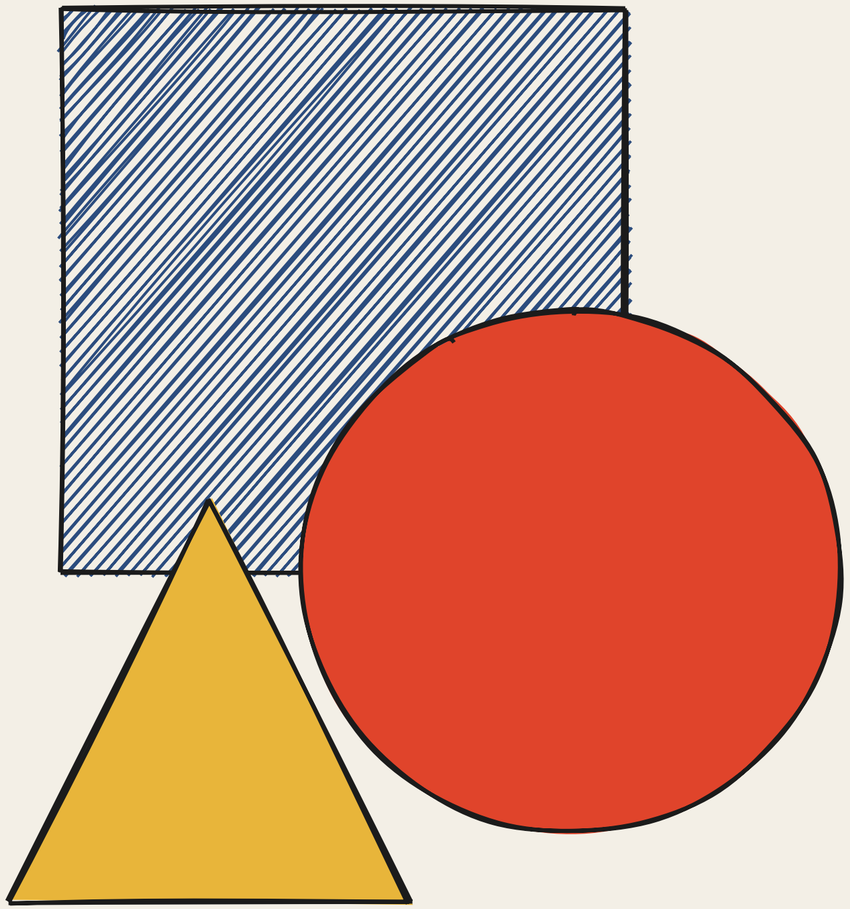
資料科學心法

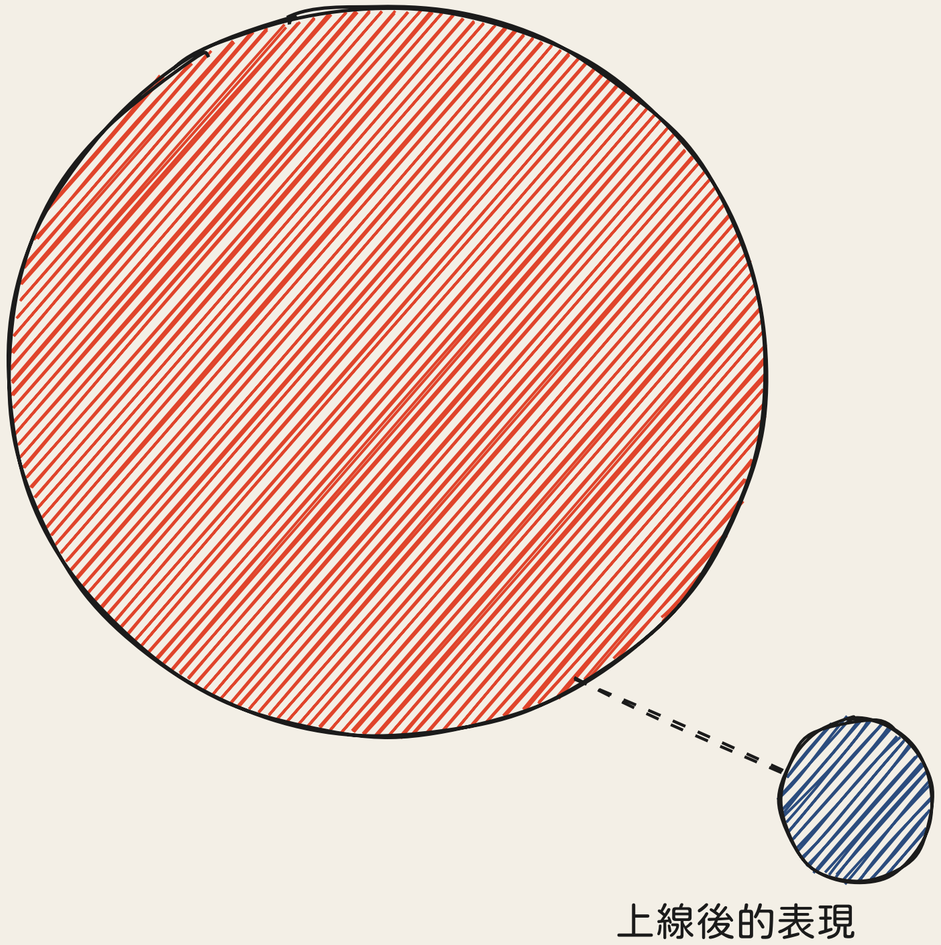
從問題定義到模型落地

大道至簡：問題定對、切分做對、
特徵講得出理由、模型最後才挑。



方＝訓練　圓＝驗證　三角＝保留集

驗證時的分數



上線後的表現

同一個模型、兩個時刻，差這麼多——問題通常不在模型本身。

為什麼要學這堂課

你知道怎麼做，卻說不出為什麼：
為什麼這樣切？為什麼選這些特徵？
這個進步，是不是運氣？

這門課補的是「為什麼」——依序四步

- 問題定對
- 切分做對
- 特徵講得出理由
- 模型最後才挑

這堂課適合誰

會跑模型，但還沒被「假的進步」坑過的人。



主要對象

會用 pandas、scikit-learn 跑模型，但說不清「為什麼這樣切、為什麼選這個特徵」的學生與轉職者。



也很適合

想建立團隊分析規範，或想把 AI 工具導入分析流程的在職分析師。



這堂課不教

程式語法、模型的數學推導、調參技巧。
要先補 pandas 的人，請先修前導課程。

學完你要能回答：為什麼選這些特徵？怎麼證明進步不是運氣？換一批資料，流程能不能重現？

先備知識：四種基本功

AI 能幫你寫程式，但它寫得對不對，要靠你看得懂、驗得出錯。



統計直覺

看分布、看樣本數、分清相關與因果

用在第 2、4 章



資料操作

分組統計、合併、時間欄位、缺失值

用在第 2、3、4 章



機器學習基礎

訓練與驗證、過擬合、分類與迴歸、常見指標

用在第 1、3、5 章



工作習慣

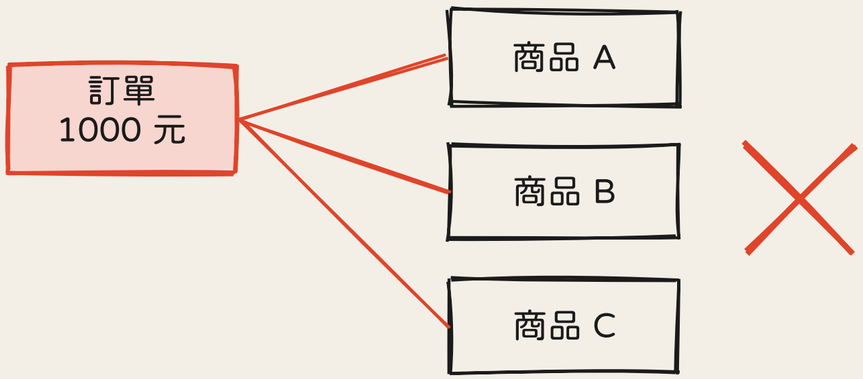
先寫下預期，再看結果；版本控制、記錄每次實驗

每一章都會用到

最常見的錯：一對多合併

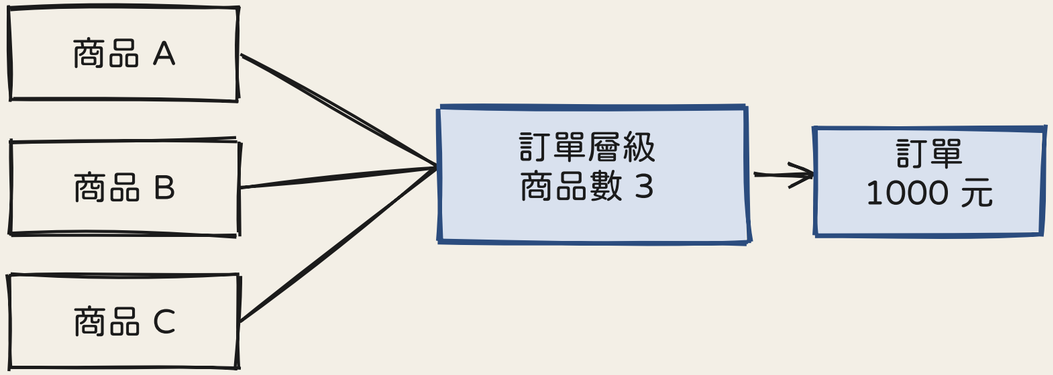
一筆訂單有 3 列商品明細。直接合併再加總金額，這筆訂單會被算 3 次。

錯誤：先合併再加總



加總：3000 元（重複 3 次）

正確：先彙總到訂單，再合併



加總：1000 元

怎麼讀：左邊一個方塊被三條線複製成三份；右邊先把明細收成一個方塊，再一對一合併。

先備：平均數會被極端值拉走

9 位員工月薪 4 萬、老闆月薪 400 萬。平均月薪 43.6 萬——沒有任何一位員工領到這個數字。



怎麼讀：一個點代表一個人，橫軸是月薪。平均數（圓）被最右邊那一點拉走；中位數（方）還留在大家身邊。看資料時，兩個一起看。

課前自我檢核

六題中有三題以上答不出來，建議先補基礎。

1. 訂單表合併明細表後列數變多了，為什麼？訂單總金額怎麼算才不會重複？
2. 正例只占 5% 時，準確率 95% 代表什麼？
3. 一個類別只有 8 筆、其中 4 筆是正例，能說「正例率 50%」嗎？
4. 用隨機切分評估「預測下個月銷量」的模型，會出什麼問題？
5. 冰淇淋銷量和溺水人數高度相關，最可能的解釋是什麼？
6. 為什麼不能用最後的測試資料來挑選模型參數？

準備工具

觀念不綁工具；實作時用下面這一套。



分析環境

Python 3.10 以上
pandas、scikit-learn
LightGBM（梯度提升樹）
Jupyter Notebook



工作習慣

git：保存每一次修改
終端機：執行指令
一份實驗紀錄：每次比較都寫下來

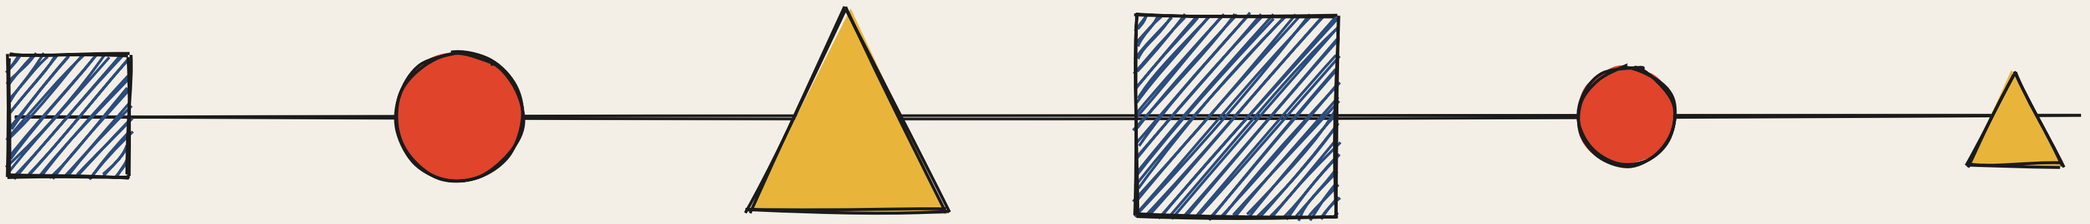


AI 助手（第 6 章）

Claude Code 或 Codex 擇一
用來執行實驗；
判斷結果仍然是你的工作

課程地圖

照順序走：後面的判斷，都建立在前面的定義上。



1 問題拆解

任務由決策決定

90 分鐘

2 EDA

為了做決定而看資料

90 分鐘

3 切分與洩漏

驗證要模擬上線那一刻

120 分鐘

4 特徵工程

把領域知識翻譯成訊號

120 分鐘

5 模型選擇

先有基準，再談升級

60 分鐘

6 人機協作

判斷結果是否可信

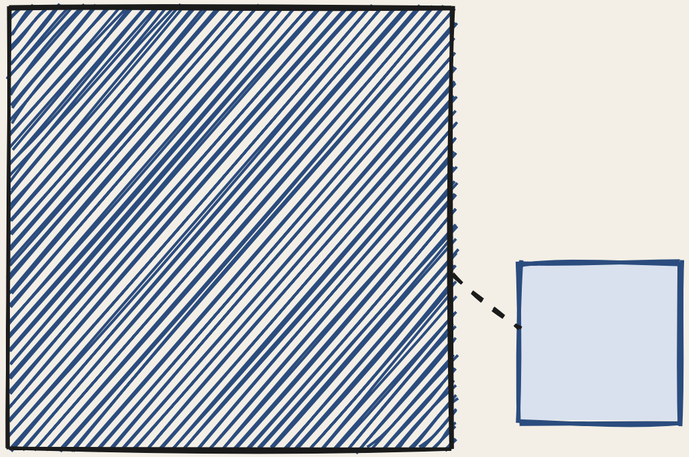
30 分鐘

重點章：第 3、4 章各 120 分鐘——切分做對、特徵講得出理由，是這門課的核心。

第 1 章

問題分析與拆解

預測任務由決策決定，不是由資料決定。先問「誰、在什麼時候、要做什麼決定」，再看資料。



學習目標

- 把模糊的商業需求，轉成完整的預測任務規格
- 說明預測時點 T0，並依決策時點推導它
- 選出符合決策的主指標與基準模型，說得出理由
- 事先訂好停止條件
- 用 MECE 把問題拆成可以驗證的小問題

本章案例　連鎖超市 200 間門市的缺貨預警：「能不能用資料提早知道哪些商品快缺貨？」

從決策倒推任務

模糊需求說出了痛點，卻沒說要預測什麼、何時預測、預測完做什麼。

「每週都有熱門商品缺貨，客人買不到就去別家。能不能用資料提早知道哪些商品快缺貨？」



區經理的需求

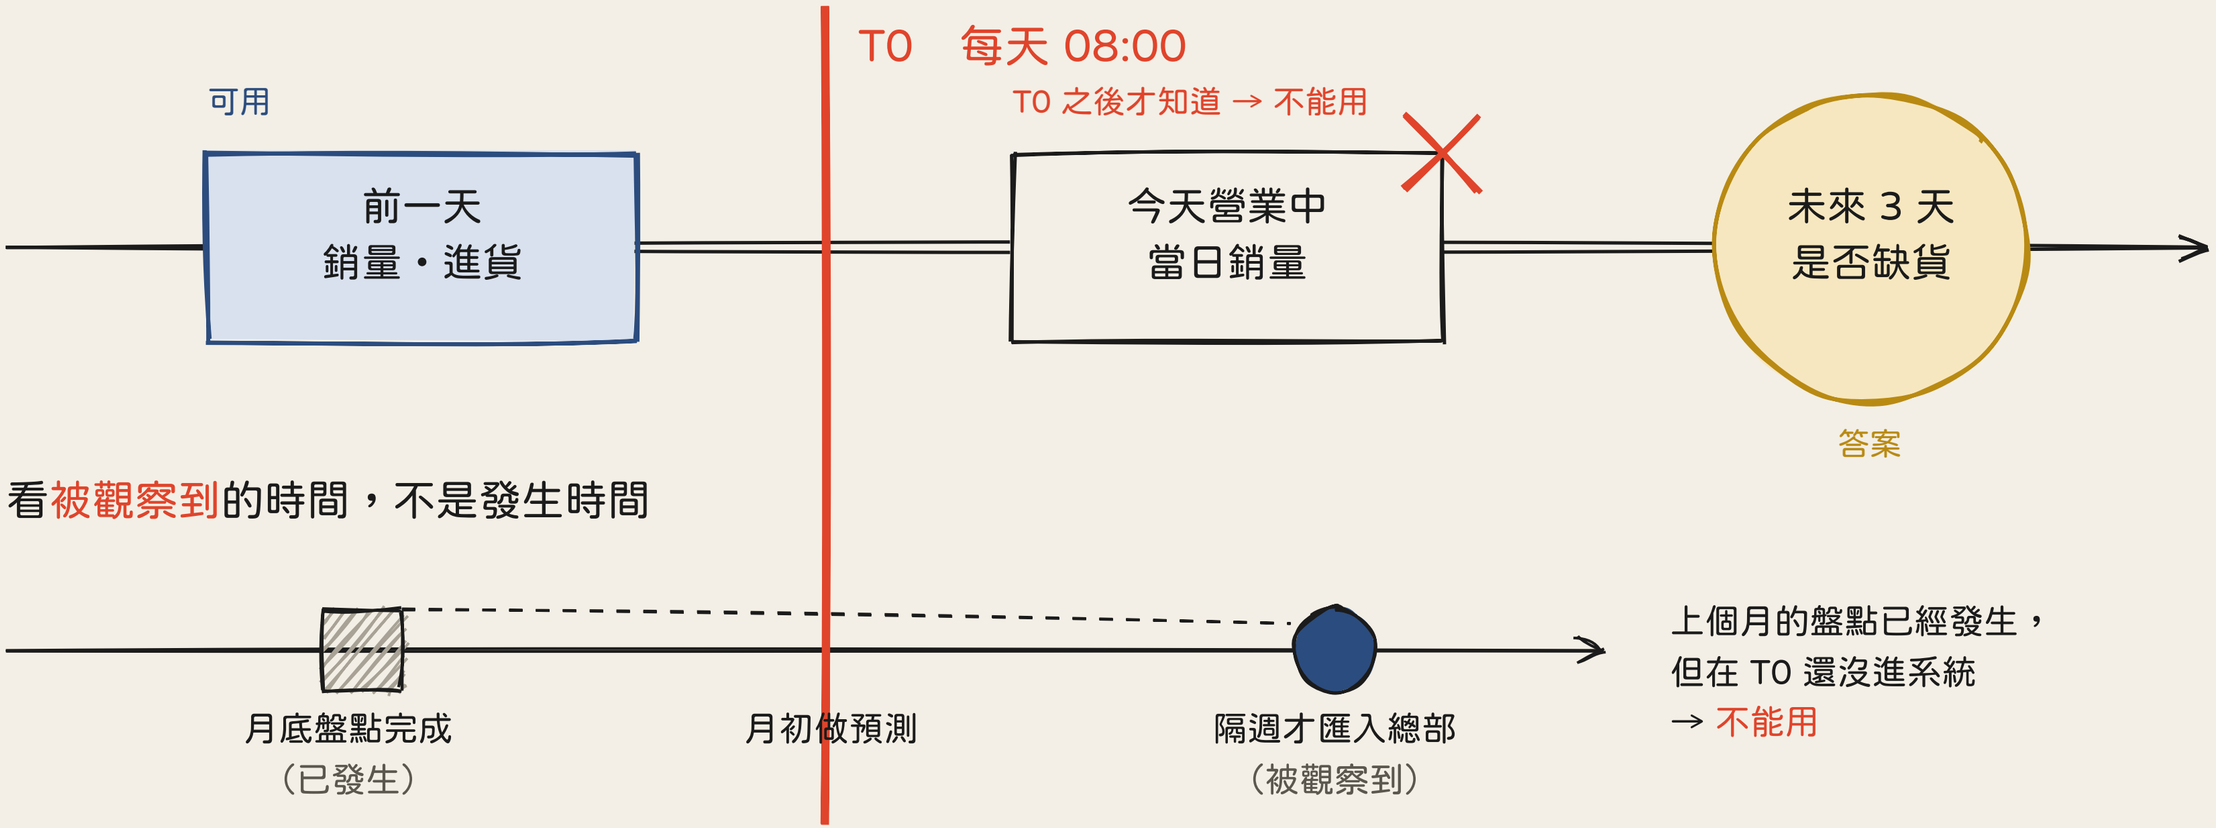
決策（前 4 格）先問　　任務（後 5 格）由決策推導

1 誰會用？ 門市店長	2 什麼時候用？ 每天早上 8 點補貨前	3 用來做什麼決定？ 哪些品項要緊急調貨
4 一天能處理多少件？ 約 20 個品項	5 預測時點 T0 每天 08:00	6 分析單位 門市 × 品項 × 天
7 目標 未來 3 天內是否缺貨（庫存降到 0）	8 主指標 Precision@20	9 基準 昨天庫存最低的 20 個品項

怎麼讀：先填靛色四格（誰、何時、做什麼決定、能處理幾件），黃色五格才由它們推出來——順序反過來，題目就會被資料綁架。

預測時點 T0：一條線切開時間

T0 由決策時間決定。T0 左邊的資訊可以用；右邊的再相關，也不能當輸入。

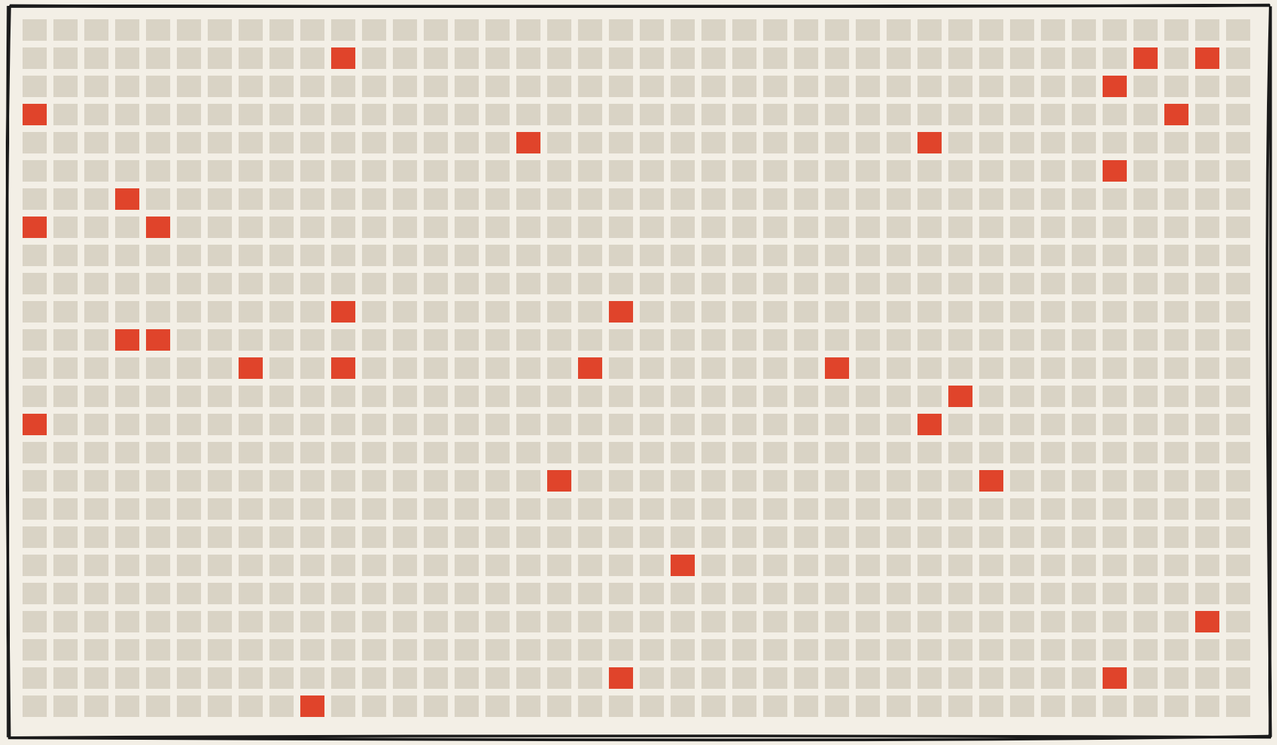


怎麼讀：檢查任何欄位，就問一句：它落在朱紅線的左邊還是右邊？「當日銷量」和答案很相關，但它在右邊。

準確率 97%，一個都沒抓到

少見事件裡，「全部猜不會發生」就能拿高分。

每天 1,000 個品項，其中 30 個會缺貨（3%）



「全部猜不缺貨」的模型

97% 準確率　　**0** 個抓到 ✕

店長一天只處理 20 項 → 只看排在最前面的 20 個



模型排出的前 20 名：中 8 個

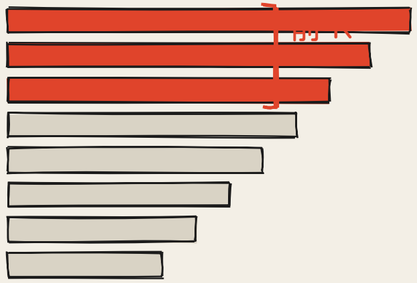
Precision@20 = 8 ÷ 20 = 40%

Lift = 40% ÷ 3% ≈ 13 倍　比亂挑好 13 倍

怎麼讀：左邊 1,000 格裡只有 30 格朱紅；右下 20 格是模型挑的前 20 名，中了 8 格。指標要量的是右下那一排。

指標要反映決策

先看決策長哪一種，再挑指標。主指標只能有一個，而且要事先決定。



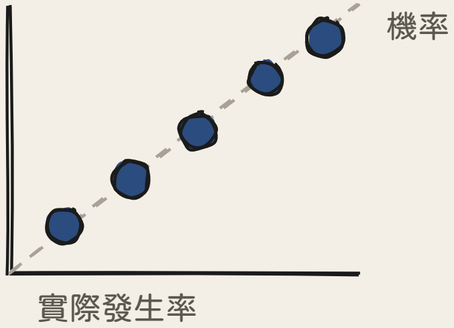
挑出前 K 名處理

少見事件（缺貨、詐騙）

用

PR-AUC、Precision@K、Lift

不要用　準確率



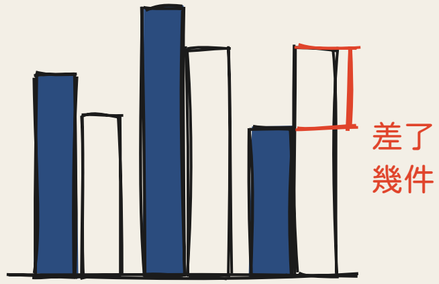
需要可信的機率

定價、保險

用

Log loss、校準曲線

不要用　只看 AUC



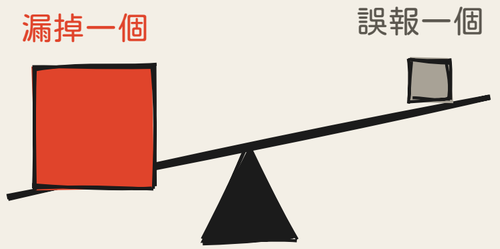
預測數量

備貨、排班

用

MAE、WAPE

不要用　只看 R^2



錯一邊代價特別高

漏診

用

指定召回率下的精確率、成本加權指標

不要用　對稱的指標

怎麼讀：缺貨預警屬第一種：主指標 PR-AUC 當裁判；向店長報告用 Precision@20、Lift@20。

沒有基準，分數沒有意義

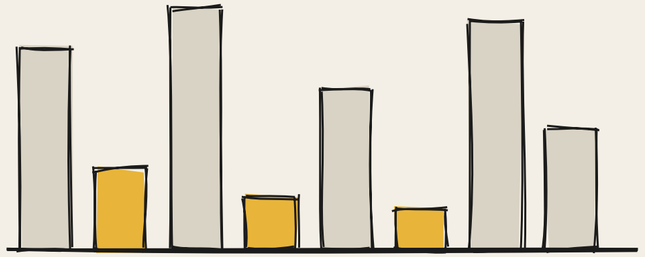
基準有兩種，各自回答一個不同的問題。



不學習的基準

每個品項都給相同分數（等於整體缺貨率）

「做模型值得嗎？」

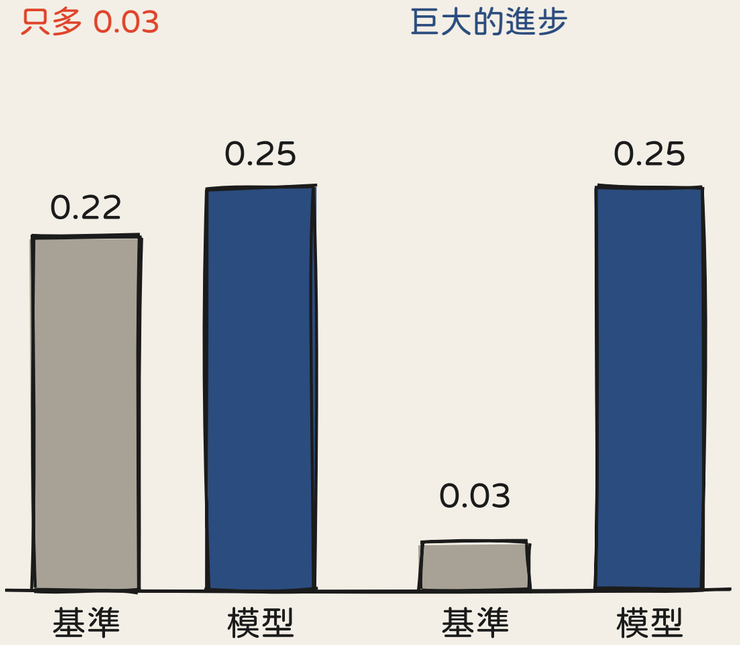


簡單規則

業務現在就在用的：「昨天庫存最低的 20 個」

「我們的努力值得嗎？」

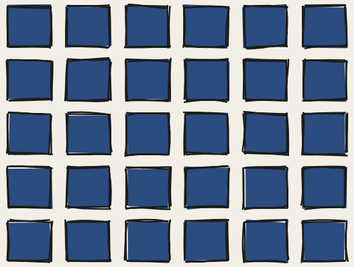
PR-AUC 0.25，算好嗎？



怎麼讀：右邊同一個 0.25，換一個基準，意義完全不同。模型至少要明顯贏過「庫存最低」規則，才有理由取代它。

停止條件：開始之前就寫好

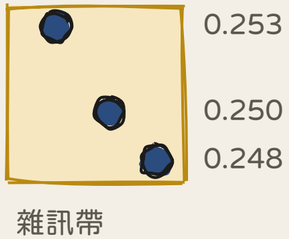
看到結果之後才決定要不要停，人很難不被結果影響。



實驗上限

最多 30 次

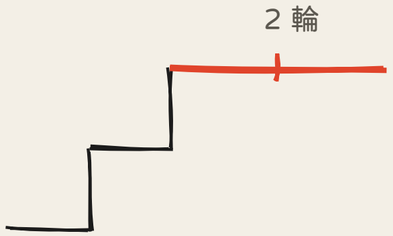
試越多次，越容易碰巧試出假的進步



最小有意義增益

PR-AUC 進步少於 0.005 不算數

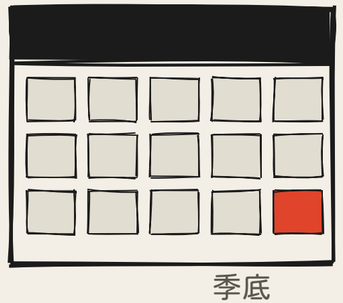
同一模型換種子跑三次，差距就有 0.005



連續無進展

連續 2 輪

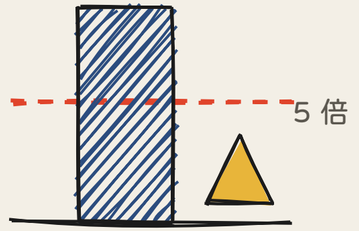
目前的方向已經走到極限



截止日

季底前上線

業務決策不會無限等待



提交門檻

Lift@20 至少 5 倍，且贏過「庫存最低」規則

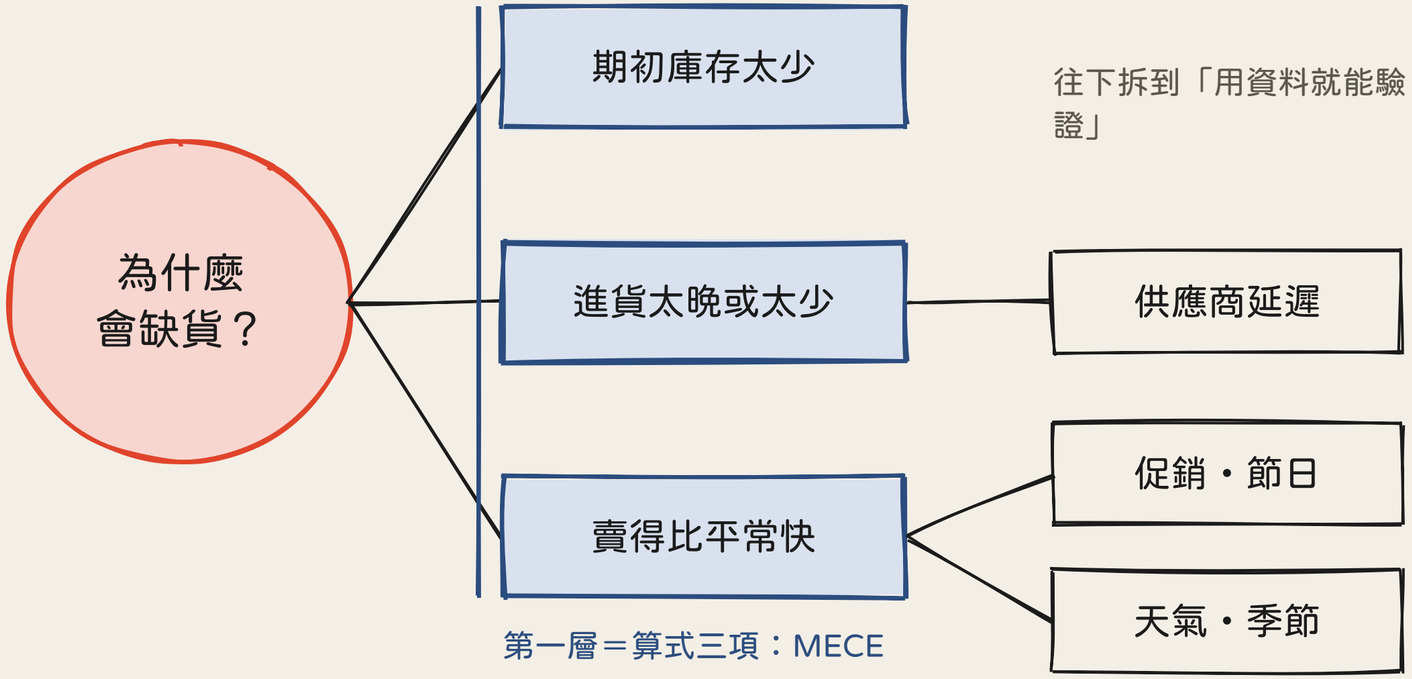
沒達標就不該上線，即使時間到了

怎麼讀：五個圖示是五道關卡，任何一道觸發就停；最後一道「提交門檻」決定的是能不能上線，不是做到哪天。

議題樹：把大問題拆到能驗證

每個分支互不重疊、合起來沒有遺漏（MECE），每層 3–4 支。

庫存 = 期初 + 進貨 − 銷售



往下拆到「用資料就能驗證」

第一層＝算式三項：MECE

三種拆法

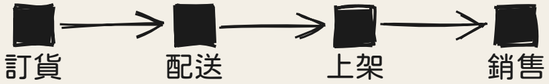
公式拆解（本案例）

目標可以寫成算式



流程拆解

目標是一連串事件的結果



利害關係人拆解

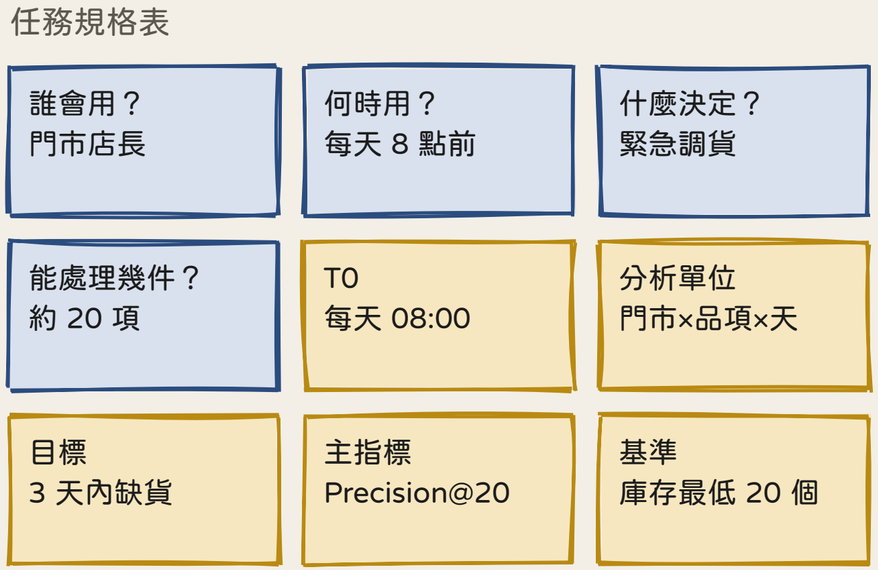
結果由多方行為共同決定



怎麼讀：從左邊的大問題往右，每層更具體；先驗證「影響大、TO 拿得到、驗證後能行動」的那一支，例如「促銷期間缺貨率是否比平常高」。

第 1 章小結

- 先有決策，才有任務：九個問題的規格表把需求變成預測任務
- T0 由決策時間決定；資訊能不能用，看「被觀察到」的時間
- 指標反映決策；少見事件不用準確率；主指標只有一個、事先決定
- 沒有基準的分數沒有意義；停止條件在看到結果前寫好
- 用 MECE 議題樹拆到可驗證的小問題，再排優先順序

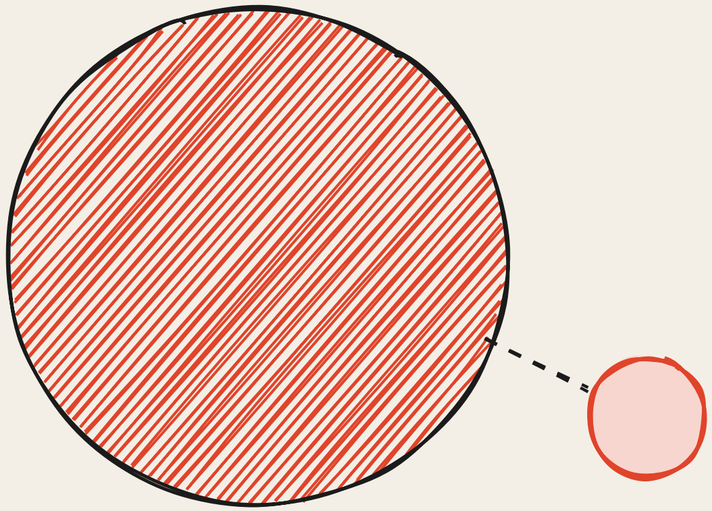


下一章：探索式資料分析

第 2 章

探索式資料分析

EDA 是為了做決定而減少不確定，不是為了畫圖。沒有預期的圖不畫。



學習目標

- 說明 EDA 的目的，以及「探索」與「驗證」的差別
- 用「由粗到細四層」的順序檢查資料
- 用 5W1H 找切角，並判斷切角好不好
- 用分層比較檢查混雜，說出相關不等於因果的五種陷阱
- 把結果寫成假設卡，轉成 T0 拿得到的特徵

本章案例　影音訂閱平台 50 萬名月付會員的退訂：T0＝帳單日前 7 天，整體退訂率約 6%。

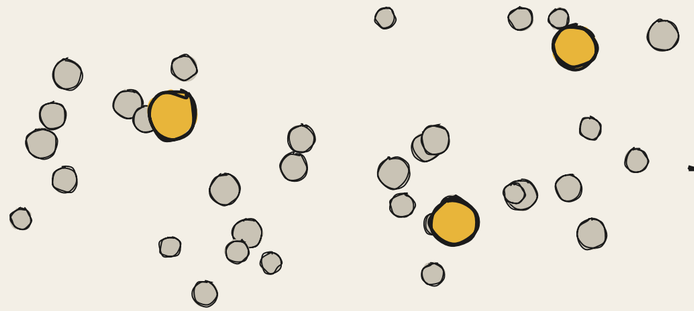
探索找線索，驗證下結論

兩個階段混在一起做，就容易被巧合騙。中間的門檻是：先寫預期。

探索

資料長什麼樣？哪裡怪怪的？

開放、好奇



產出：線索

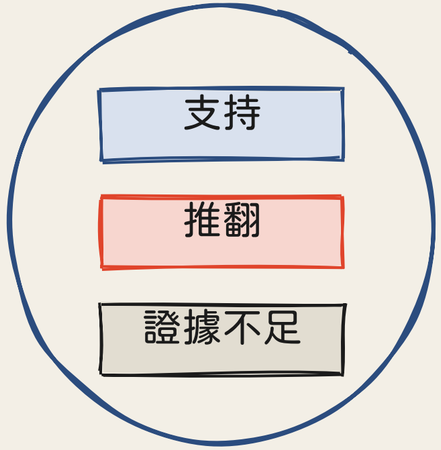
先寫預期

「我預期月繳超過 400 元的會員，退訂率約是其他會員的 1.5 倍。」

驗證

我的猜測對不對？

嚴謹、懷疑



沒寫預期時　結果 1.5 倍 →「果然貴的方案容易退訂」；結果 1.05 倍 →「果然價格不是主因」。怎樣都「果然」，就學不到東西。

怎麼讀：左邊散點只是線索；必須經過中間的黃色門檻寫下數字，進到右邊才算結論——被推翻的時候，才是眞正學到東西。

EDA 由粗到細四層

每一層都建立在前一層上：前一層「沒問題」，才進到下一層。

示意

① 單變量
資料乾淨嗎？

→

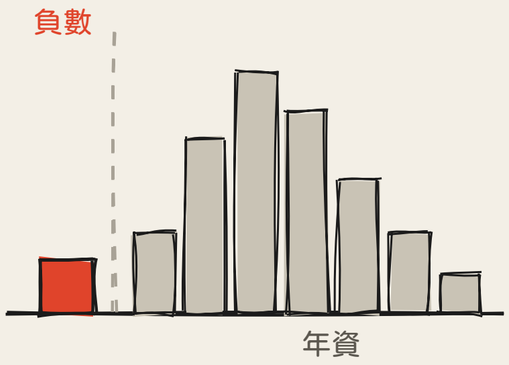
② 目標 × 特徵
和退訂有關嗎？

→

③ 分層
是不是別的因素造成的？

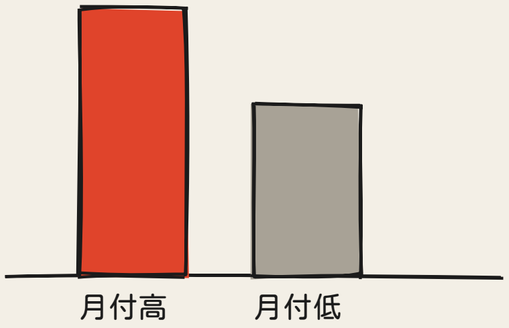
→

④ 時間
關係穩定嗎？



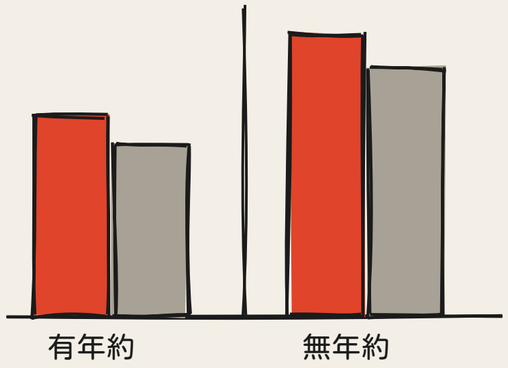
本案例發現

年資有負數；方案價格缺失集中在某個月



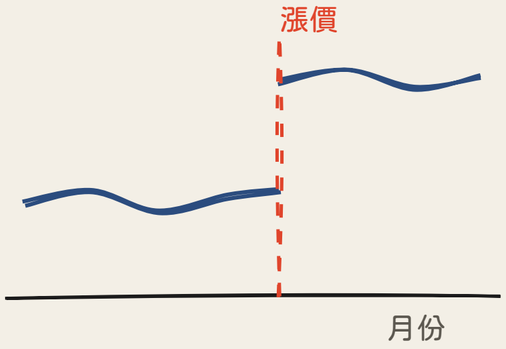
本案例發現

月付金額高的，退訂率較高



本案例發現

控制「是否有年約」後，價格的影響變小



本案例發現

某次漲價後，退訂率整體跳升

怎麼讀：由左往右，每格回答一個問題。最常見的錯：跳過 ① 在髒資料上找規律，或停在 ② 把關聯當成原因。

切角：從哪些角度分組比較

先從第 1 章議題樹的葉節點挑，再用 5W1H 補漏。

Who 是誰？

新會員 vs 老會員、年齡層、是否家庭方案

What 用什麼？

方案類型、常看的內容類別

Where 在哪裡？

地區、主要使用的裝置

When 何時？

加入的月份、距離上次觀看幾天

How 怎麼用？

付款方式、是否自動續約

How much

月付金額、每週觀看時數

好切角的四個條件

有預期
跑之前寫得出「A 組比 B 組高」

樣本夠
每組至少數百筆，否則比例亂跳

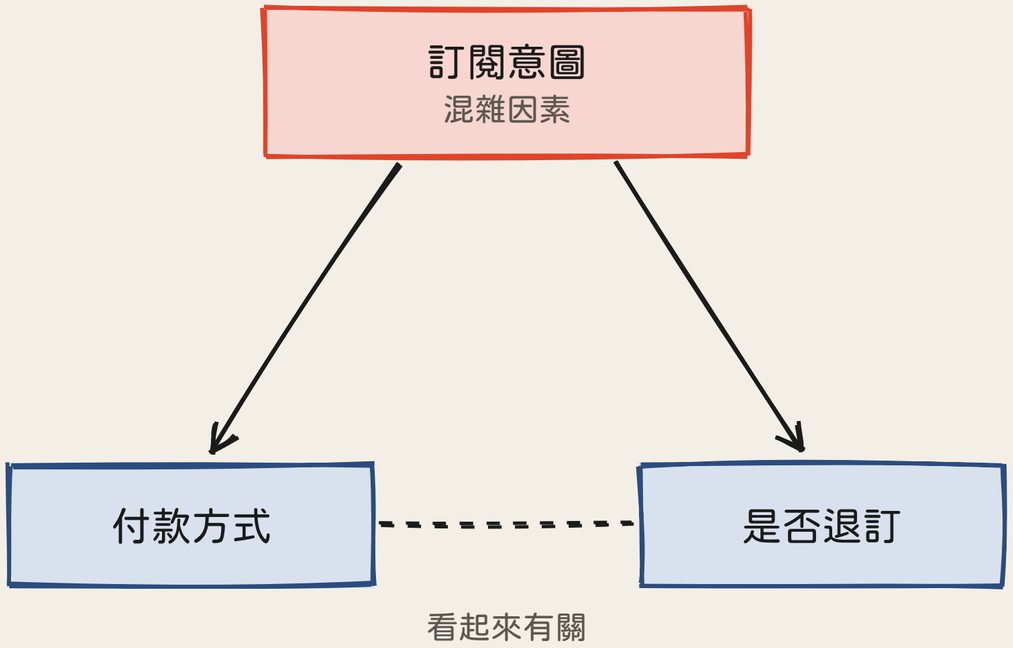
可行動
結果會改變特徵設計或業務作法

T0 拿得到
拿不到的只能理解原因，要標「T0 不可得」

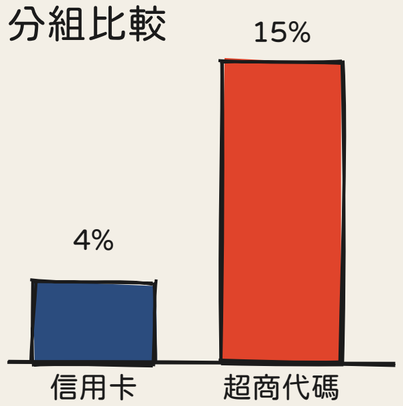
怎麼讀：左邊六格產生候選切角，右邊四關負責篩掉；四關都過的切角，才值得跑一次分組比較。

相關不等於因果：混雜因素

付款方式和退訂看起來有關，其實兩者都被「訂閱意圖」影響。



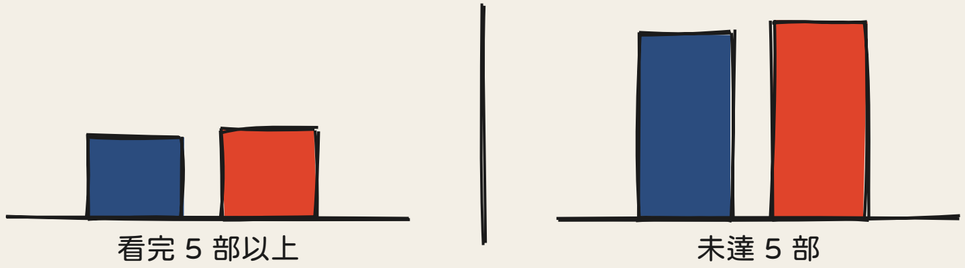
生活版：天氣熱，冰淇淋賣得多、游泳的人也多——
冰淇淋銷量和溺水人數就「相關」了



推廣信用卡綁定後，退訂率卻沒有下降

分層比較 示意

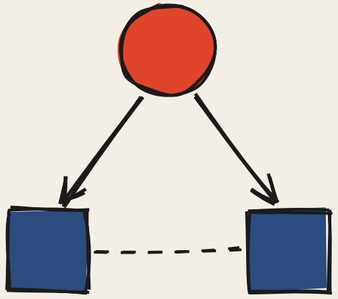
依「第一個月看完 5 部以上影片」分兩層，各自再比一次



怎麼讀：分層就是把最上面的「訂閱意圖」固定住，看虛線還在不在；每一層內差距都消失，代表原本的關聯來自混雜。

相關不等於因果：五種陷阱

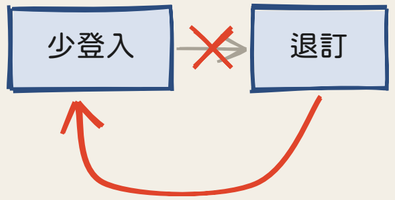
看到兩件事一起變動，先問是不是落入其中一種。



混雜

訂閱意圖同時影響付款方式與退訂

檢查：分層比較



反向因果

很少登入的人容易退訂——也可能是決定退訂的人才不登入

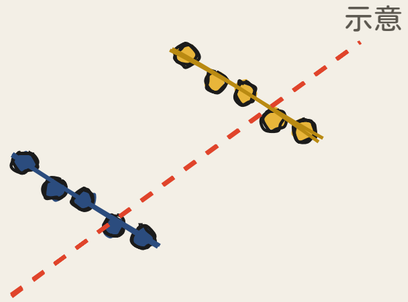
檢查：看時間先後



選擇偏差

只分析填過滿意度問卷的會員，他們本來就比較投入

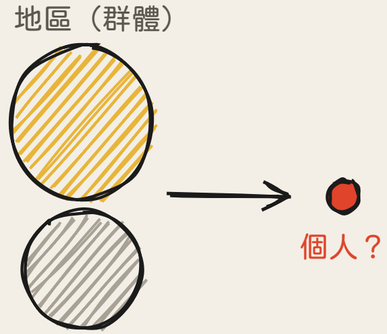
檢查：哪些人沒進到資料？



Simpson 悖論

整體看家庭方案退訂率較高，但每個價格帶內都比較低

檢查：分層後重算



生態謬誤

退訂率高的地區平均年齡較低，不代表年輕人較易退訂

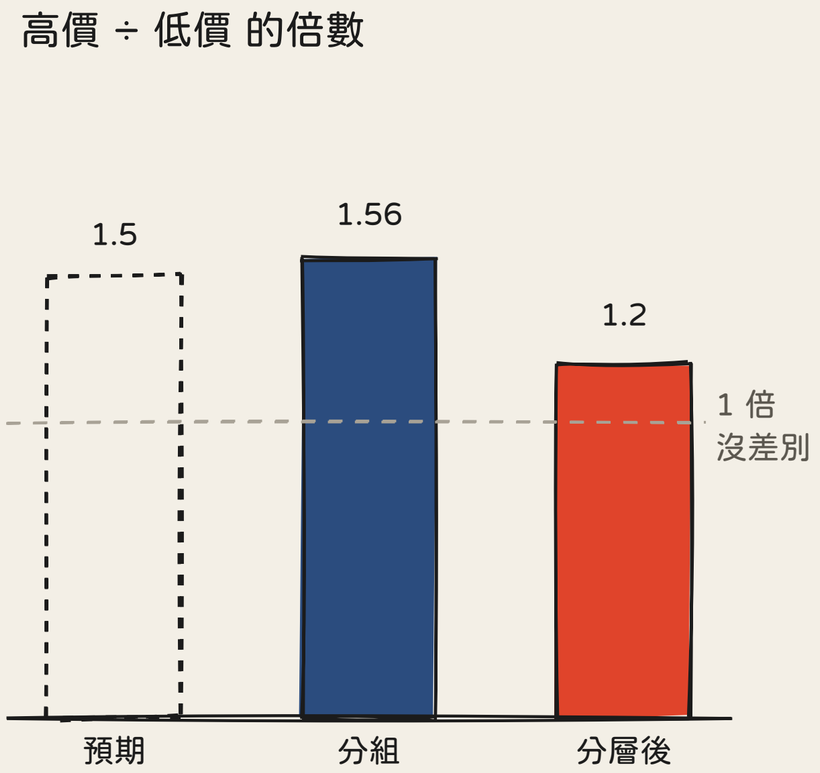
檢查：回到個人層級

怎麼讀：每個小圖是一種結構。分層之後關聯仍在，也只排除了一個混雜因素——要證明因果，通常需要實驗。

EDA 的產出是假設卡

每張卡記錄一個假設從預期到結論的完整過程；被推翻的也要留下。

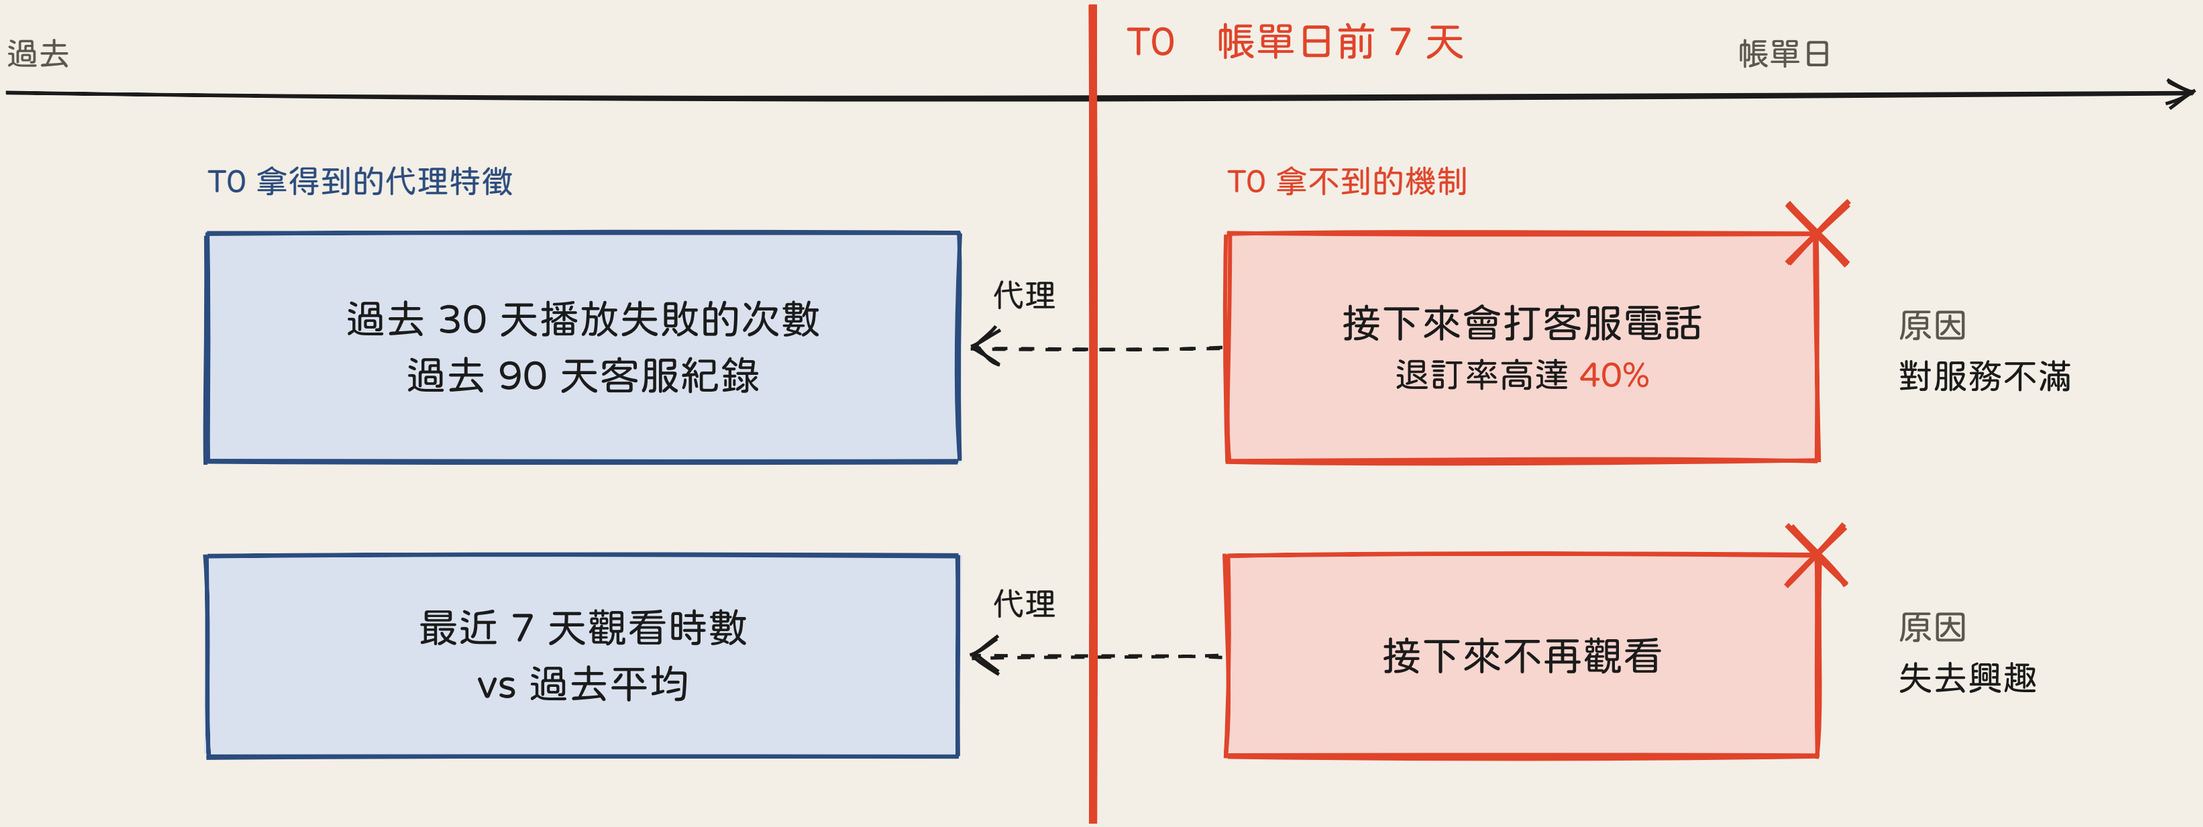
假設	月付金額越高，越容易退訂
預期	高價方案退訂率約是低價的 1.5 倍
分組結果	高價 8.1%（n=120,000）vs 低價 5.2%（n=380,000），1.56 倍
分層結果	控制「是否有年約」後，倍數降為 1.2 倍
競爭解釋	高價方案的會員比較常是「為了某部劇才加入」
結論	支持，但影響比預期小
TO 可用的特徵	月付金額、是否有年約



怎麼讀：右邊三根柱子：分組結果幾乎命中預期，但控制年約後縮到 1.2 倍——結論是「支持，但影響比預期小」。

T0 拿不到的原因，找代理

最能解釋結果的因素，往往在預測當下還不存在。



怎麼讀：朱紅線右邊的機制不能當輸入，只能拿來理解原因；沿著虛線往左，找一個 T0 拿得到、又和它高度相關的替代品。

第 2 章小結

- EDA 是為了做決定而減少不確定；不改變決定的圖不必畫
- 先寫預期再看結果：探索得到線索，驗證得到結論
- 四層由粗到細檢查；切角來自議題樹與 5W1H
- 相關不等於因果：分層能排除混雜，但不能證明因果
- 產出是假設卡；T0 拿不到的機制要轉成代理特徵



下一章：資料切分與洩漏

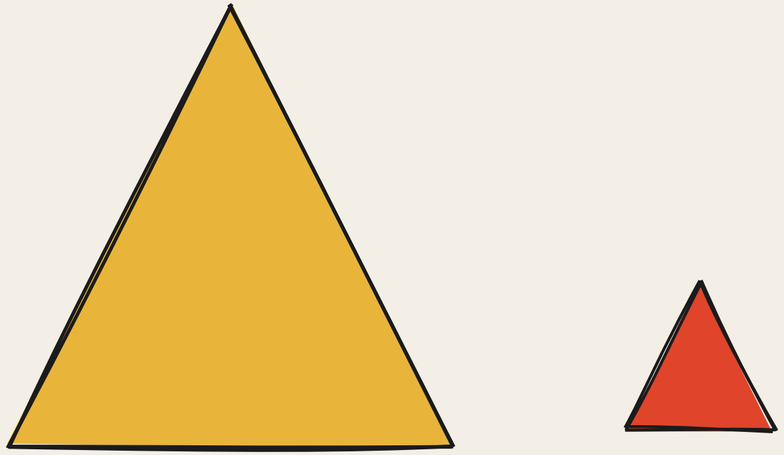
第 3 章

資料切分與洩漏

驗證要模擬上線那一刻。

一句話擋下大多數洩漏：

「預測那一刻，這個值存在嗎？」



學習目標

- 用「考試」比喻說明訓練、驗證、保留集，以及保留集為什麼只能用一次
- 依上線情境選切分方式：新對象用群組、未來事件用時間
- 說明滾動起點回測與季節性樸素預測
- 用同 fold 配對比較判斷進步是否穩定
- 辨識五種洩漏，說明擾動測試與對抗驗證

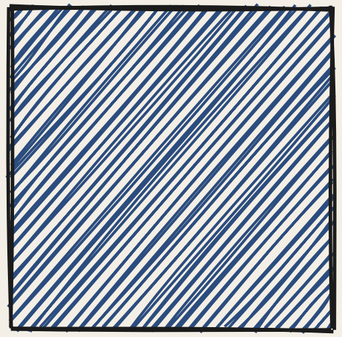
本章案例

A 醫院再入院：病人出院時，預測 30 天內會不會再住院（同一人可能住院很多次）

B 門市銷量：每週日晚上，預測下週一到週日每天的銷量

三份資料，就像準備考試

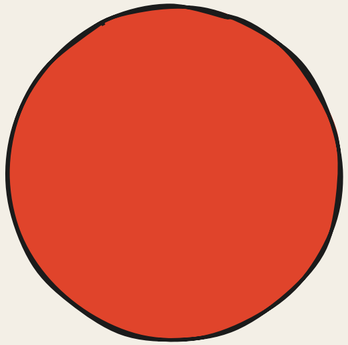
練習、模擬、正式上場——用途不同，能看的次數也不同。



課本與習題

訓練集

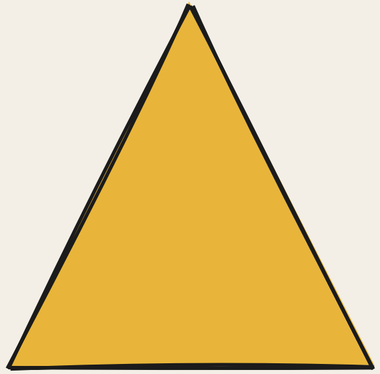
模型拿來學



模擬考

驗證集

比較做法、挑最好的



正式考試

保留集

最後估計上線表現

為什麼要三份？

試了 50 種做法、挑驗證分數最高的那個——這個最高分有一部分是運氣。

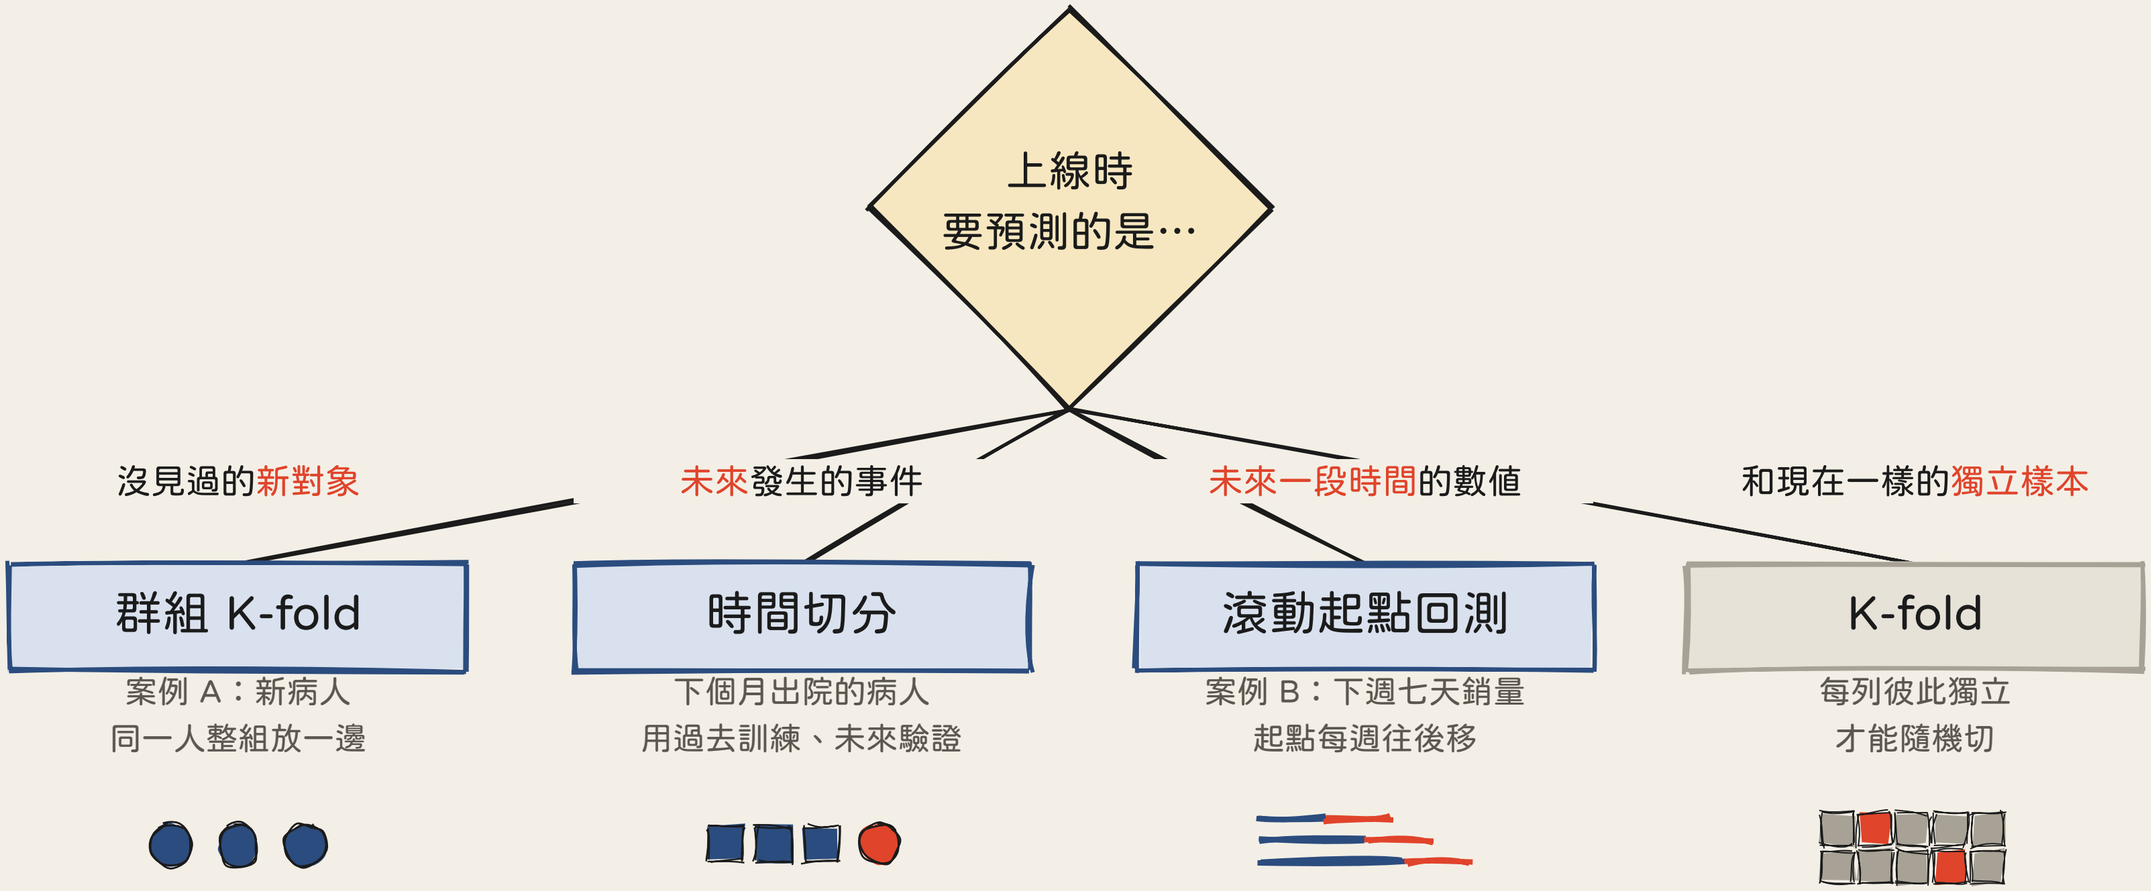
需要一份從沒參與挑選的資料，最後給誠實的分數。

可以看幾次	無限次	很多次	只看一次
			

怎麼讀：由左往右，能看的次數越來越少；三角形只能打開一次——看了再回頭改模型，它就變成另一份驗證集。

切分方式由上線情境決定

驗證要模擬「上線時會遇到的資料」——先回答：上線時要預測的是什麼？

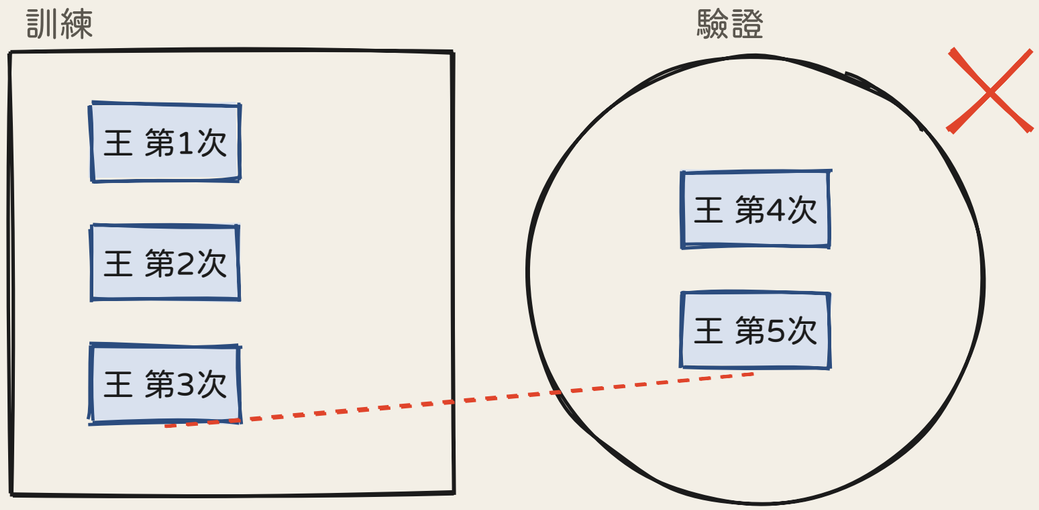


怎麼讀：從菱形出發選一條路。若同時符合兩條（例如「未來的新病人」），兩個條件都要滿足：同一人不跨兩邊，驗證時間也要在訓練之後。

新的對象：群組 K-fold

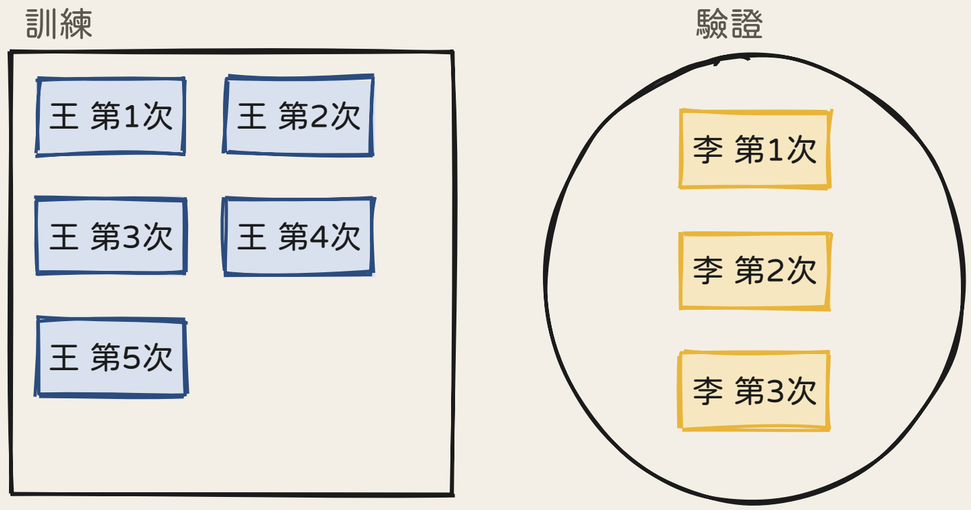
王先生住院 5 次，資料裡就有 5 列。隨機切分會把同一個人拆到兩邊。

錯誤：隨機切分



模型在驗證時其實在「認人」：72 歲、糖尿病、常再入院——它見過。分數虛高，上線遇到新病人就掉下來。

正確：同一人整組放同一邊



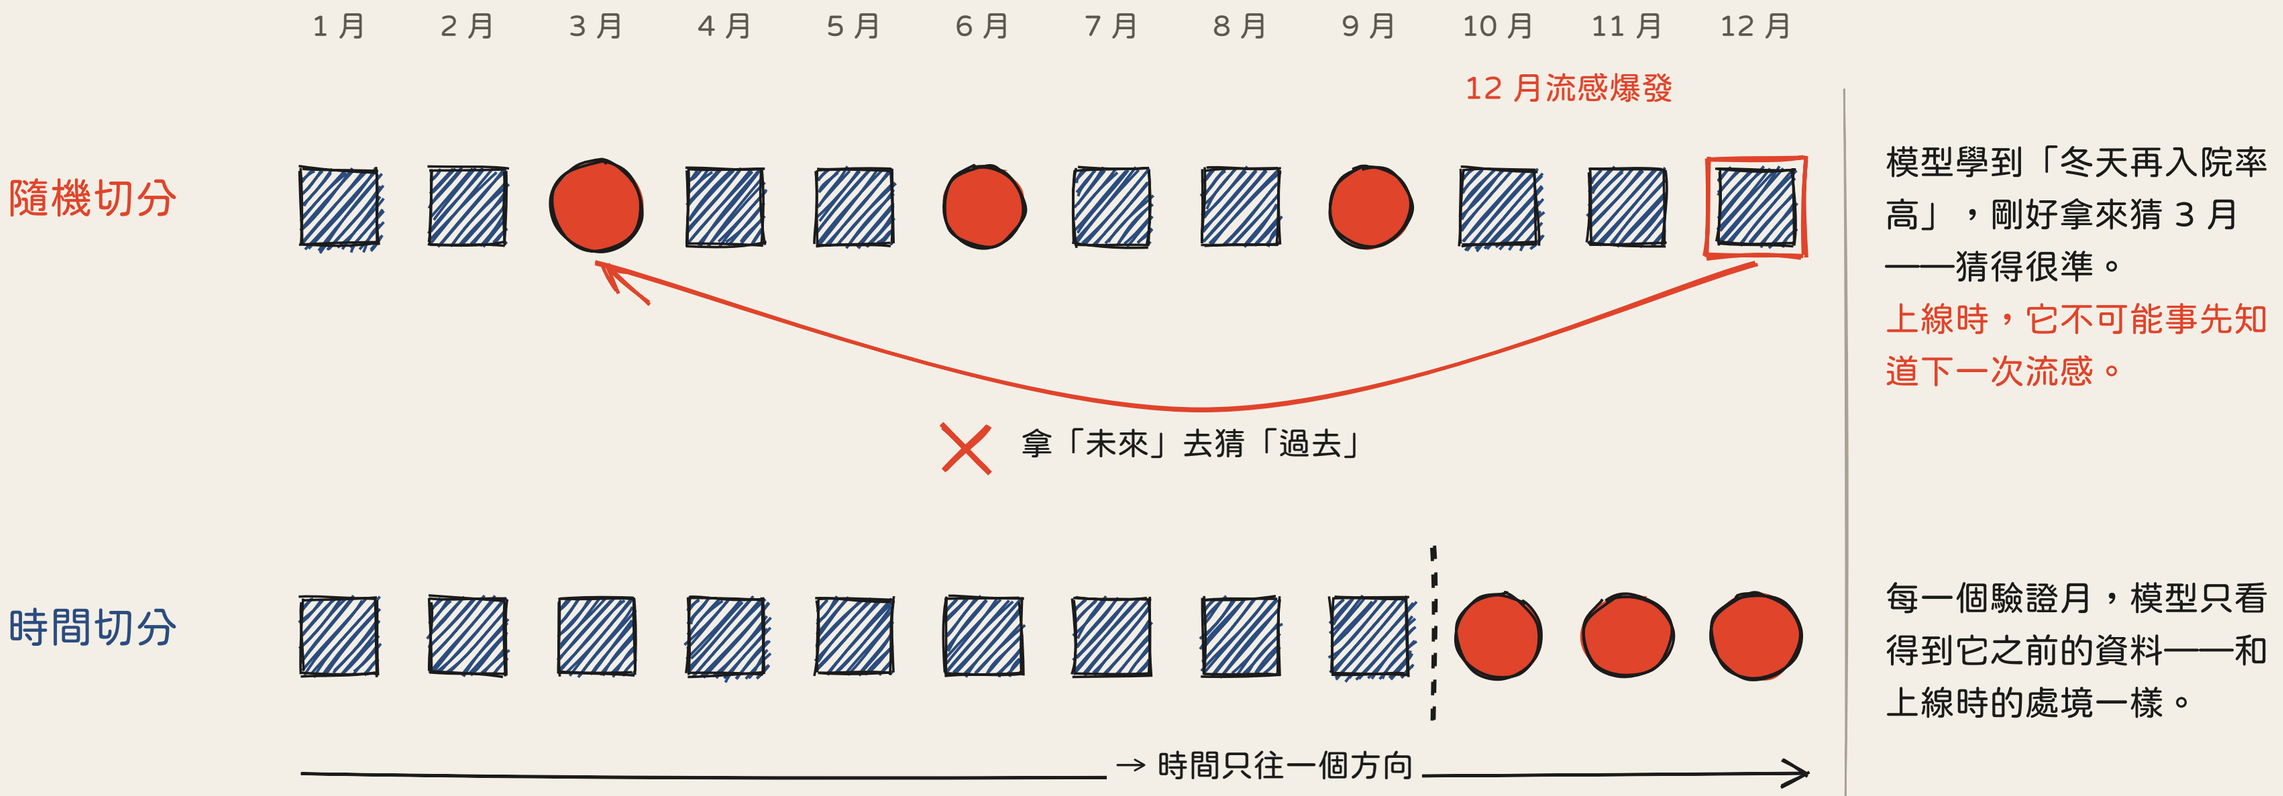
驗證集裡每一位，模型都沒見過——正好模擬上線遇到新病人。

群組＝病人 ID／客戶 ID／門市 ID／機台 ID

怎麼讀：看顏色有沒有跨過中線。切分的單位，是上線時「新出現」的那個東西。

隨機切分，讓未來跑進訓練集

醫院要預測下個月出院病人的再入院風險。同一年的資料，兩種切法（月份分配為示意）：



模型學到「冬天再入院率高」，剛好拿來猜 3 月——猜得很準。

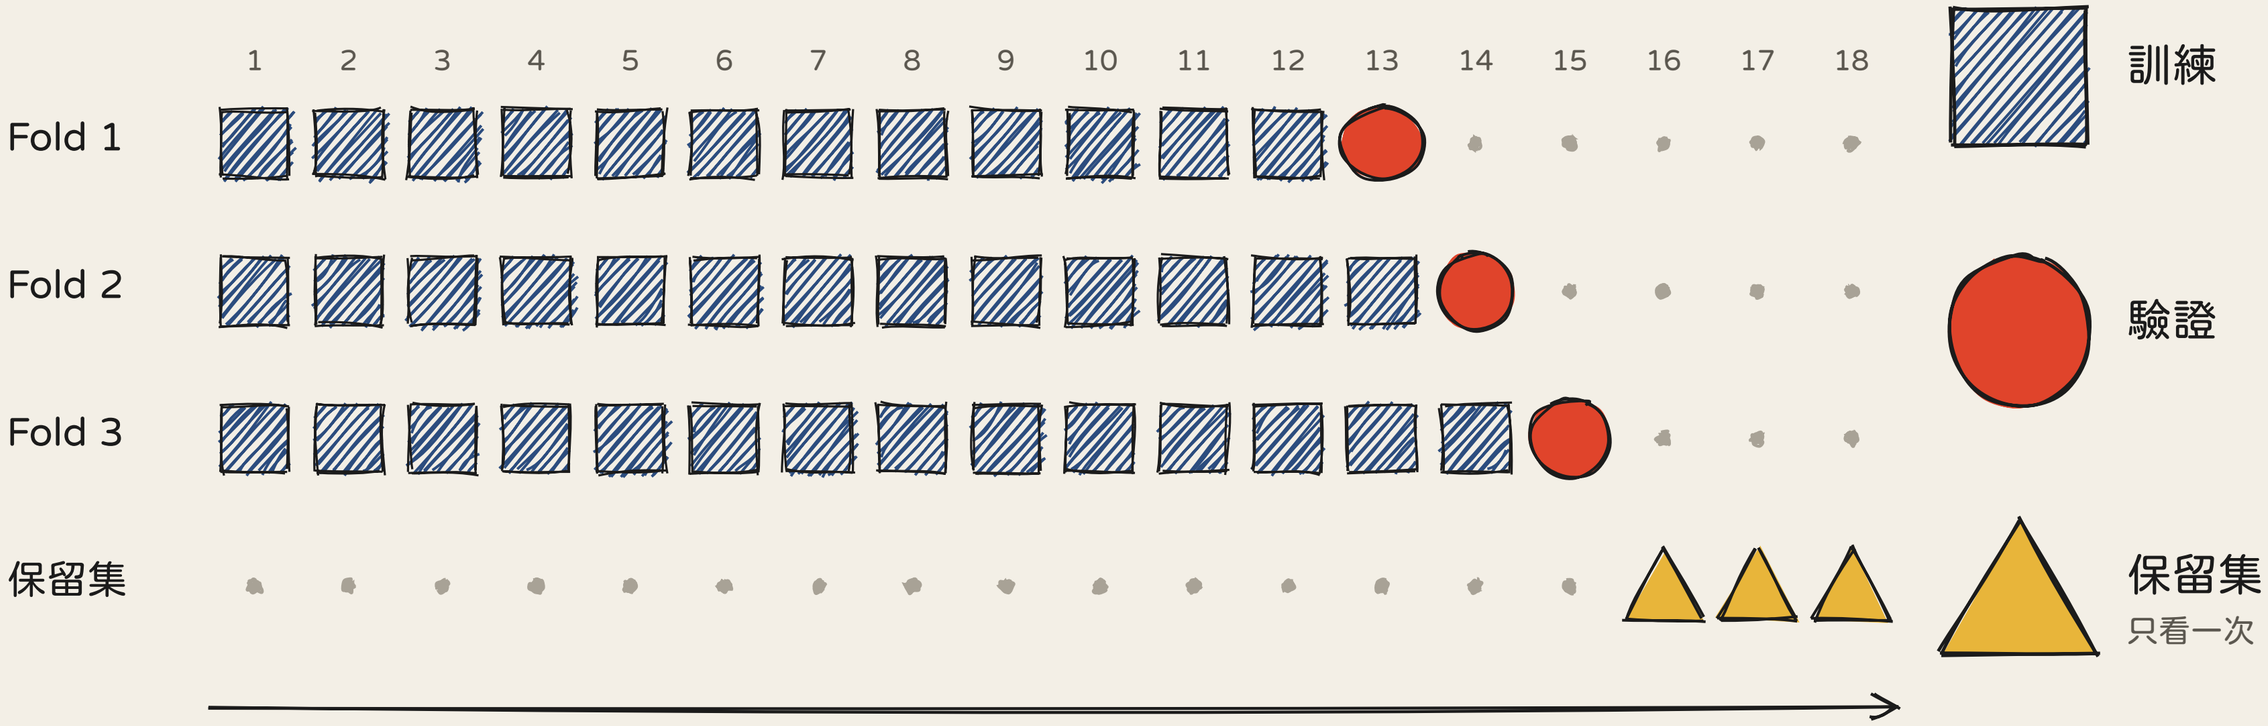
上線時，它不可能事先知道下一次流感。

每一個驗證月，模型只看得到它之前的資料——和上線時的處境一樣。

怎麼讀：看圓形（驗證）的位置：上排它散在方形（訓練）中間，下排它永遠在方形的右邊。

時間切分：用過去預測未來

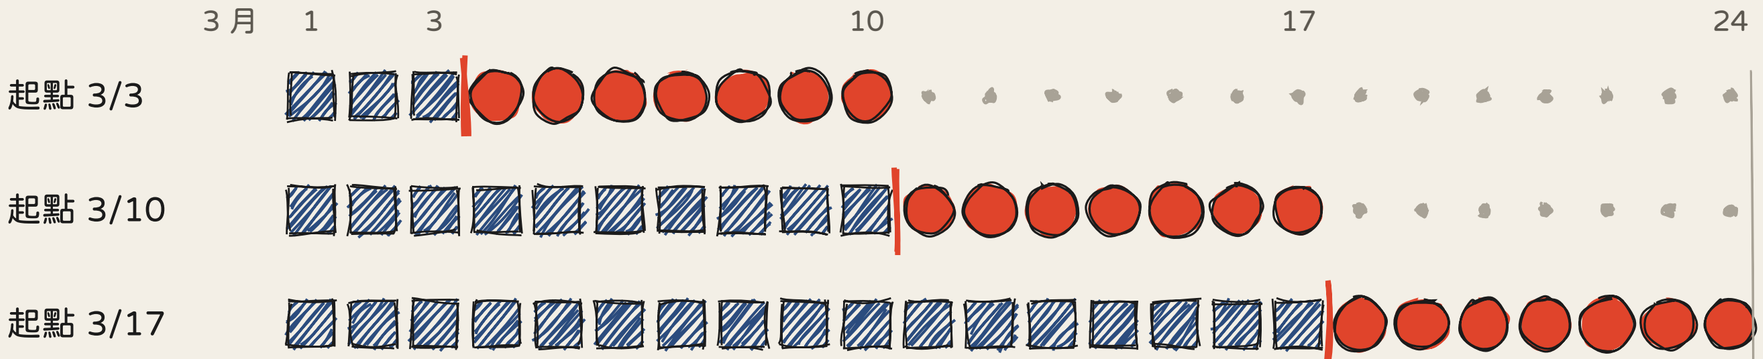
擴張視窗——每一次驗證，訓練都從起點開始，而且比上一次多一個月。



形狀即概念：方形是訓練、圓形是驗證、三角形是保留集。每一列由左往右是時間，圓形永遠在方形的右邊——模型只能用過去預測未來。

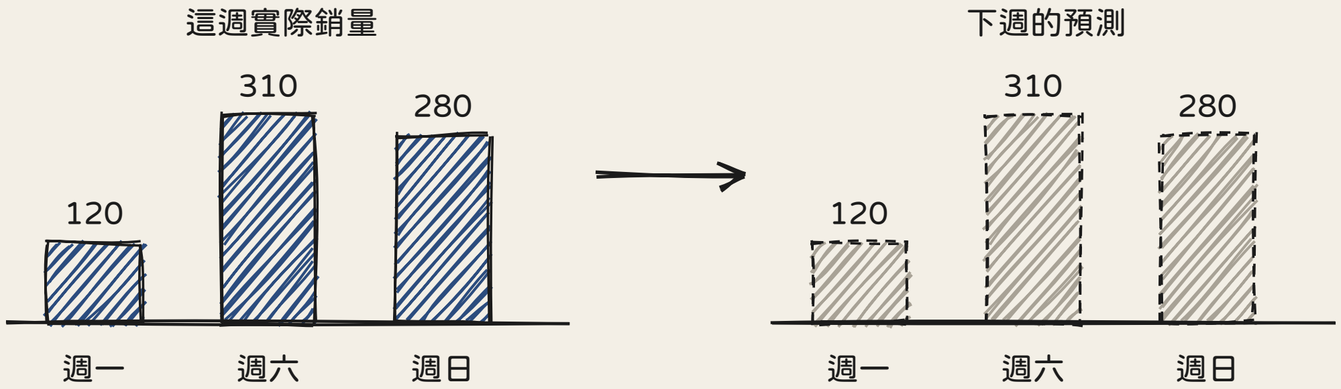
滾動起點回測

案例 B：假裝站在過去某個週日晚上，只用那天以前的資料，預測接下來 7 天（h = 7）。



每一次的處境，都和「週日晚上預測下週」一模一樣；把每次的誤差平均，就是評估結果。

基準：季節性樸素預測＝照抄上週同一天

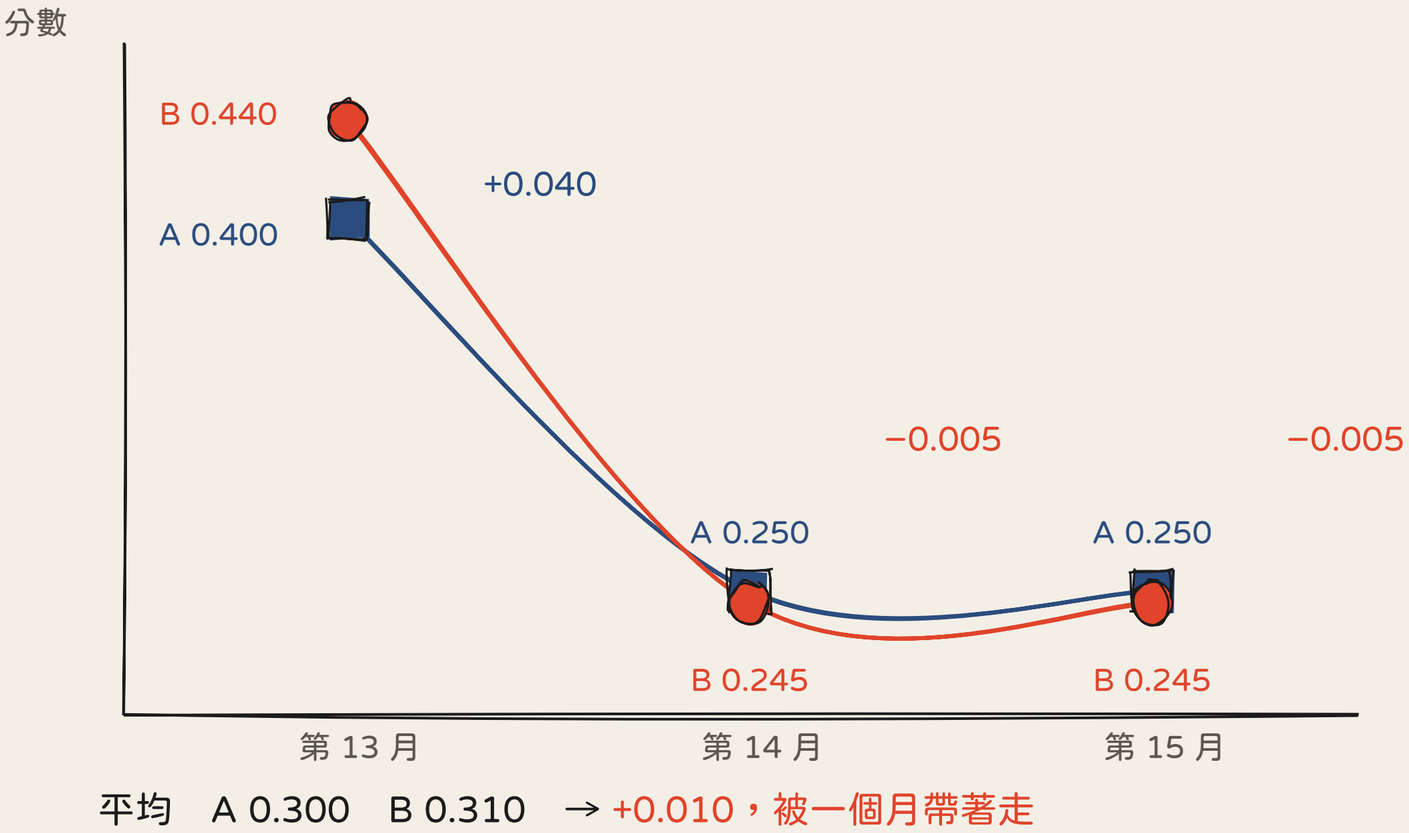


模型在回測中誤差沒有明顯小於它 → 沒學到比「照抄上週」更多的東西。

怎麼讀：朱紅直線是起點，每週往右移一次；方塊是可用的過去，圓形是要預測並比較的 7 天。

進步是眞的嗎？同 fold 配對比較

平均高 0.010 的做法 B，只在第 13 月大贏，另外兩個月都輸。



平均　A 0.300　B 0.310　→ +0.010，被一個月帶著走

每個 fold 都進步

平均進步大於波動 → 穩健，可以採用

平均進步，但有 fold 退步

不能宣稱有效，可能只是某段時間剛好有利

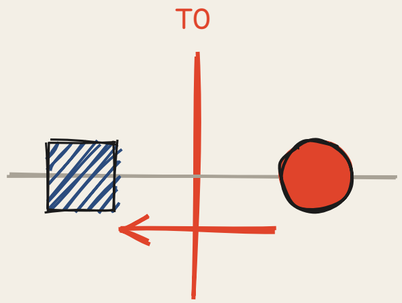
某一次突然大幅進步

先懷疑洩漏

怎麼讀：月份之間的落差（0.40 vs 0.25）遠大於兩個做法的差距——所以要在同一個月上配對比，看 B 是不是每個月都贏。

五種資料洩漏

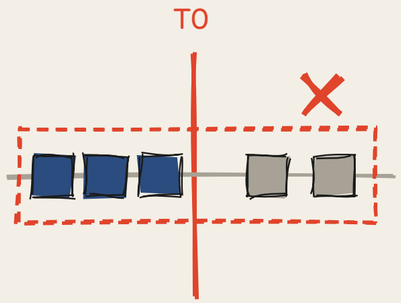
洩漏＝用到上線時拿不到的資訊。它讓每一個 fold 都變好，所以配對比較擋不住。



目標洩漏

用「出院後 30 天內門診次數」預測再入院——它本身就是結果的一部分

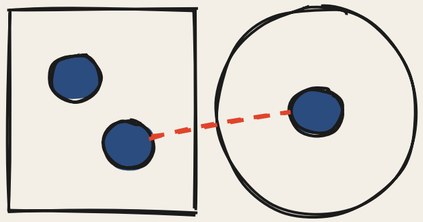
- 每個欄位標記 T0 之前或之後才知道



時間洩漏

「過去平均住院天數」用了全部資料，含這次之後的紀錄

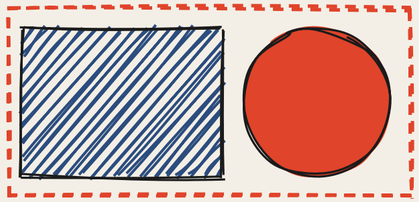
- 只用 T0 之前，並排除自己



群組洩漏

同一位病人的住院紀錄，分散在訓練與驗證兩邊

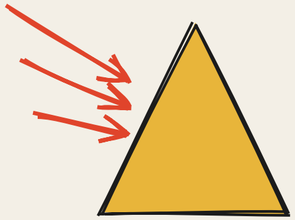
- 群組切分



前處理洩漏

先用全部資料算平均補缺失、做標準化，再切分

- 先切分，前處理只用訓練資料算



驗證污染

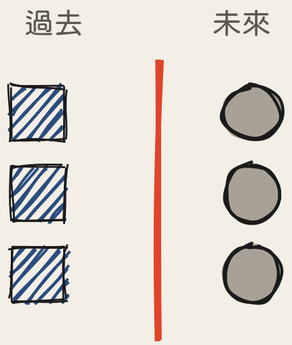
反覆看保留集調模型；或先在全部資料上挑特徵再做 CV

- 保留集只看一次；挑特徵在每個 fold 內做

怎麼讀：上排圖示都是同一個動作——朱紅的東西越過了它不該越過的線。每一欄最後一行是防法。

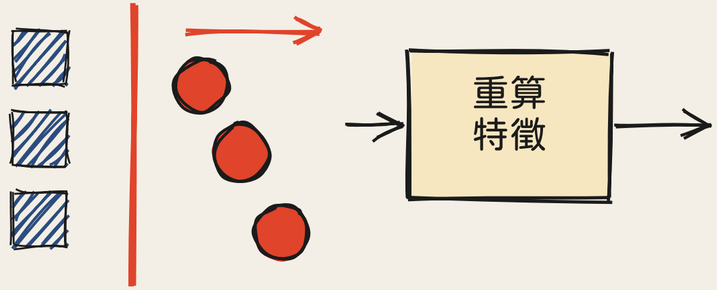
擾動測試：故意竄改未來

合法的特徵只用過去——未來怎麼改，它都不該變。變了，就是偷看了未來。



1 選切點

切點之後視為「未來」

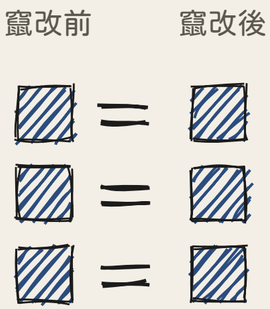


2 竄改未來

打亂數值，或把事件只往更晚移

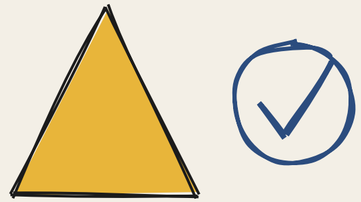
3 重算

重新計算所有特徵



4 比對過去列

切點之前的特徵值必須完全一樣



5 驗證測試本身

寫一個故意洩漏的特徵，確認抓得到

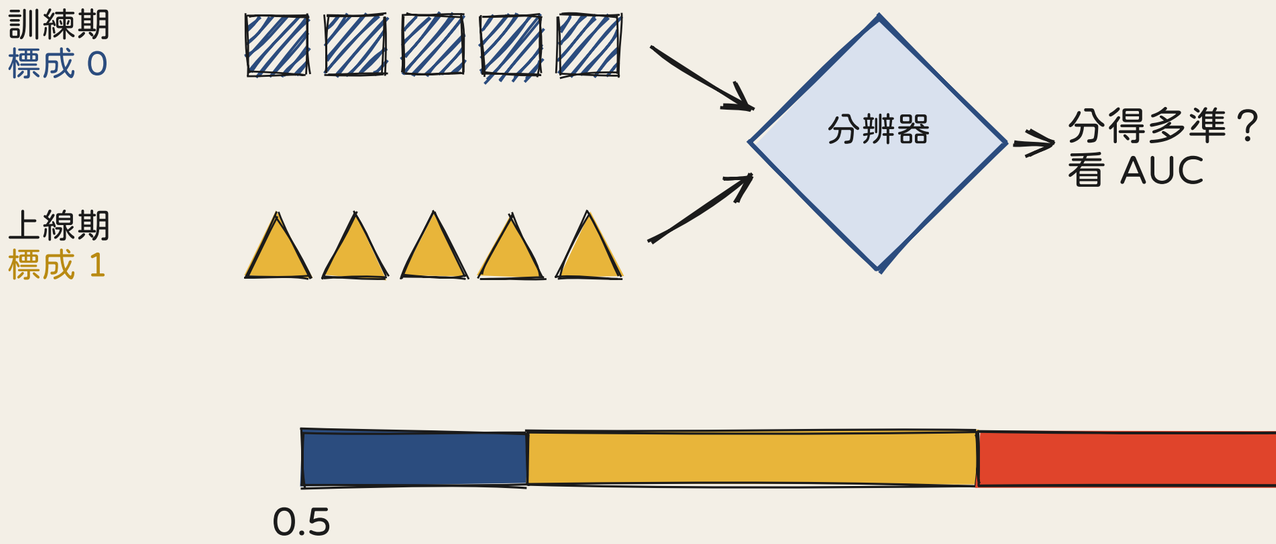
像懷疑學生偷看答案卷，就把答案卷偷偷換掉——他的答案跟著變，就證明他有偷看。

第 2 步若把事件往前移，未來會跑進過去，連合法特徵也會變，造成誤判。

怎麼讀：由左往右五步；重點在第 4 步的等號——切點之前的值一個都不能動。

對抗驗證：兩期資料長得一樣嗎？

訓練一個「分辨器」，猜一筆資料來自訓練期還是上線期。分得越準，漂移越大。



附帶好處

分辨器最依賴的欄位，就是最會隨時間改變的欄位——例如「資料建立日期」「累計就診次數」。

改成比率，或改用近期時間窗。

約 0.5：分不出來

兩期很像，驗證分數大致可信

0.6–0.8：有些差異

檢查是哪些欄位造成的

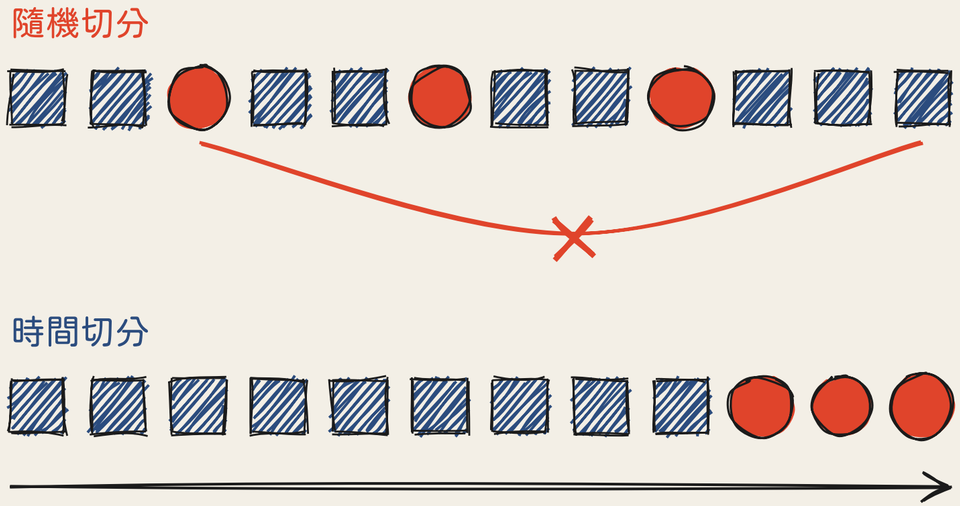
接近 1：一猜就中

驗證可能高估上線表現，要找出原因

怎麼讀：上半是做法（0 和 1 丟給分辨器），下半是刻度尺：指針越往右，驗證分數越不能代表上線。

第 3 章小結

- 訓練集用來學、驗證集用來挑、保留集只在最後看一次
- 切分方式由上線情境決定：新對象用群組、未來事件用時間、未來一段數值用滾動起點回測，並和季節性樸素預測比
- 判斷進步用同 fold 配對比較，每一次都進步才算穩健
- 穩健不等於合法：五種洩漏都要防，擾動測試抓計算過程裡的洩漏
- 世界會變：用對抗驗證檢查訓練期與上線期是否一致



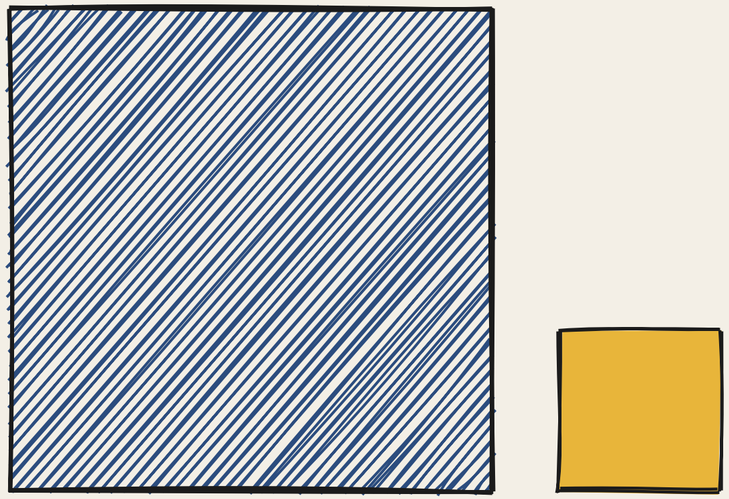
驗證（圓）永遠在訓練（方）的右邊

下一章：特徵工程

第 4 章

特徵工程

特徵＝把領域知識翻譯成模型看得懂的訊號。
好特徵講得出：來自哪個假設、
預測當下拿得到、加進去眞的有進步。



學習目標

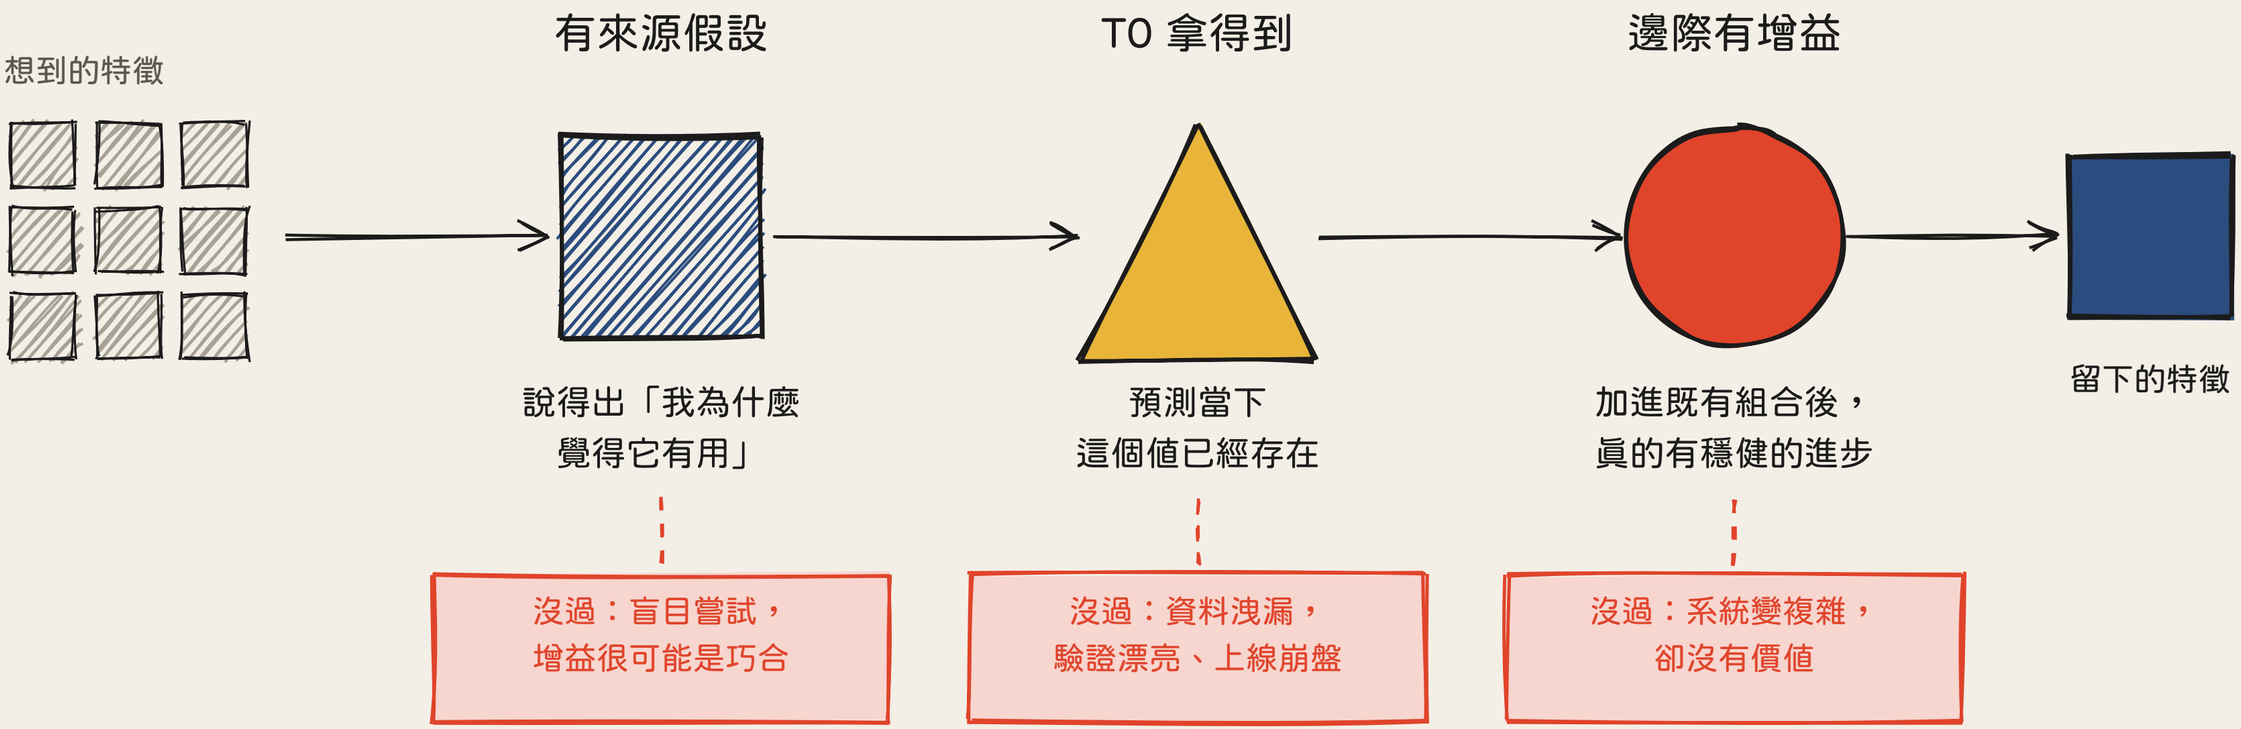
- 說明為什麼表格資料上，特徵工程常比換模型有效
- 依資料型態與模型種類選擇處理方式，並說出理由
- 用時點正確的方式計算歷史統計特徵，不偷看未來
- 用消融實驗與邊際價值判斷特徵值不值得留下

本章案例

家電零售商：在顧客結帳的當下，預測這筆訂單 30 天內會不會被退貨。

好特徵要過三道關

寫不出理由的特徵，就不要做：先寫特徵卡（定義＋理由），再寫程式。

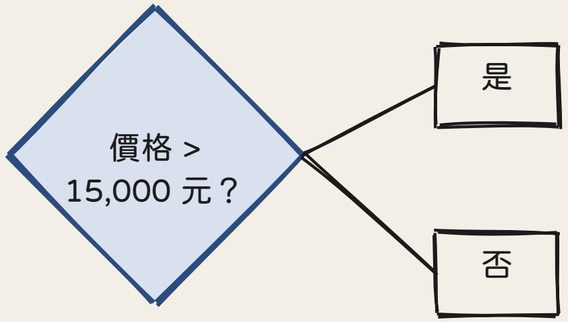


怎麼讀：左邊一堆想法由左往右過關，每一道關往下掉的，都對應一種上線後的代價；能走到最右邊的只剩少數。

同一個「價格」，兩種看法

前處理要配合模型「看資料的方式」，不是照抄教學。

樹模型＝一連串是非題



改用「千元」記錄：
問「> 15 千元？」
切出的訂單完全相同

→ 縮放沒有影響

線性模型＝加權總和

風險 = 0.3 × 價格 + 2.1 × 是否週末 + …



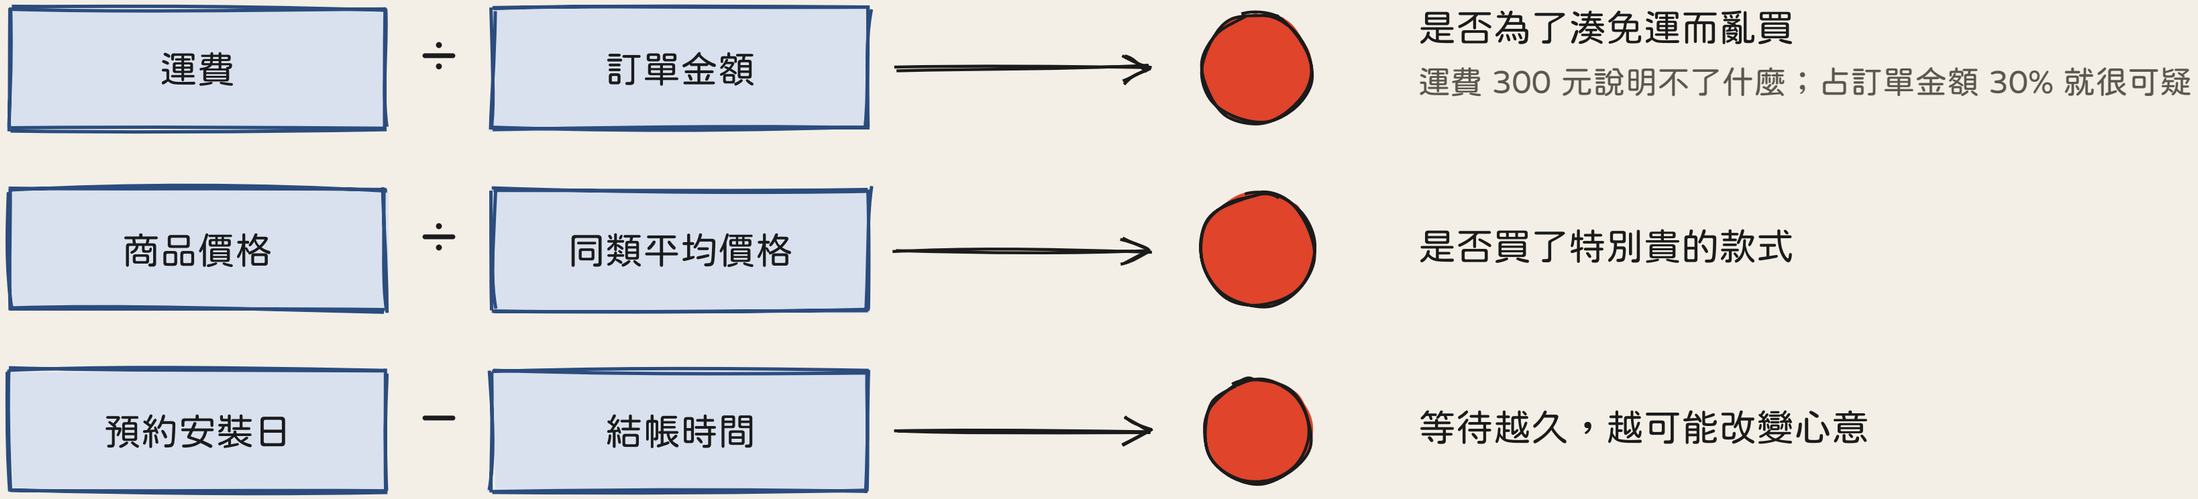
數字直接乘權重：大小差太多，正則化懲罰不公平 → 需要縮放

	縮放、標準化	偏態（取 log）	缺失值	類別欄位	非線性、交互作用
樹模型	不需要	不需要	多數可直接處理	原生支援，或 目標／次數編碼	自己會學
線性模型	需要	有幫助	補值＋缺失旗標	one-hot	要人手動做 （分箱、相乘）

怎麼讀：上排看兩種模型怎麼「吃」同一個數字；下排是結論——用樹模型把時間花在新特徵，用線性模型還要調數字的形狀。

數值欄位：組合起來才有意義

把業務上眞正在意的關係，直接算給模型看——比率與差值常比原始欄位更有力。



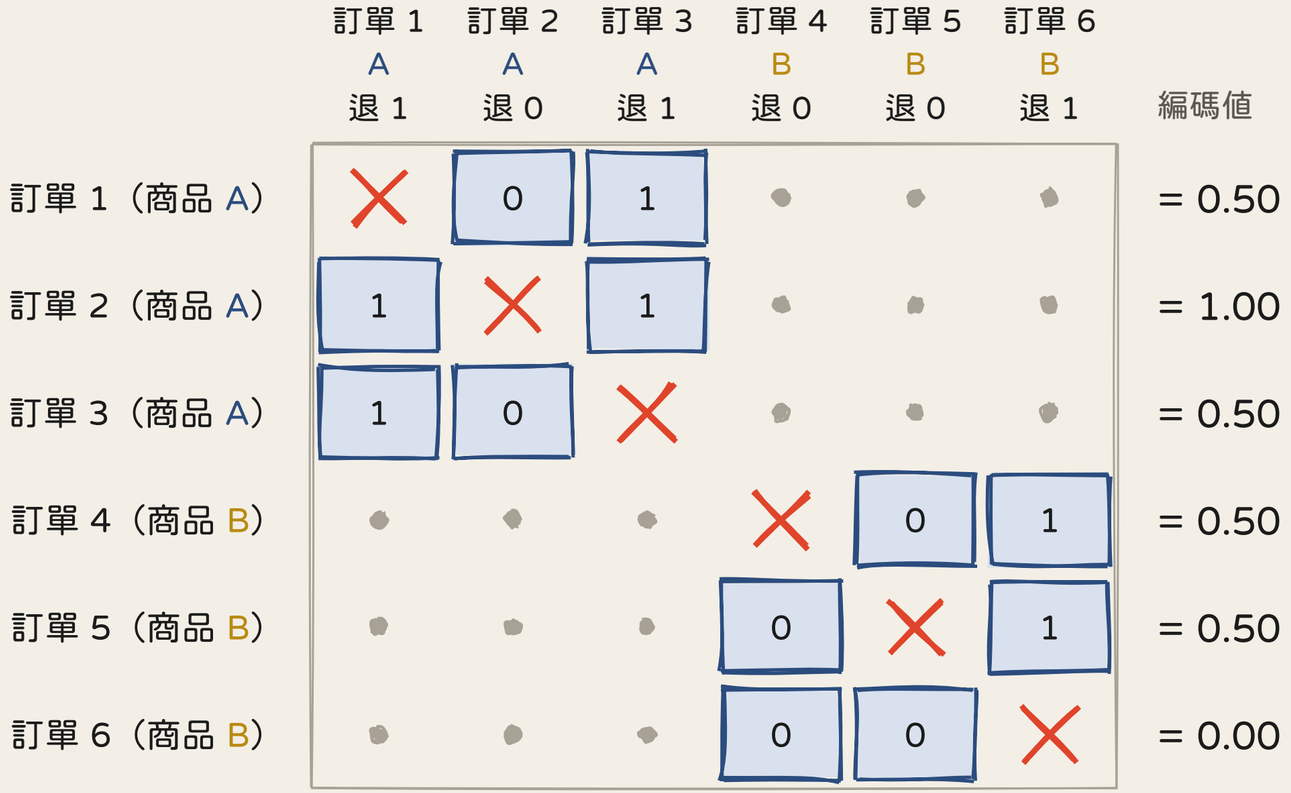
數值欄位的六種問題與做法

缺失	偏態長尾	尺度不同	極端值	非線性	單獨無意義
補中位數 ＋缺失旗標 全部模型	log(1 + 金額) 200,000 → 12.2 線性、神經網路	標準化 線性、神經網路、KNN	先查是不是錯誤 眞實的再截尾 線性	分箱、樣條 線性	比率、差值 （上方三例） 全部模型

怎麼讀：上方每一列「兩個方塊合成一個圓」——兩個原始欄位，合成一個有業務意義的訊號；下方六格是數值欄位的檢查清單。

目標編碼：只准用別人的答案

把商品換成「過去的退貨率」很有力；但每一列的編碼，不能含它自己的答案。



同商品、其他份：拿來算

自己：不准用

不同商品：不相干

分成 3 份：{1, 4}、{2, 5}、{3, 6}

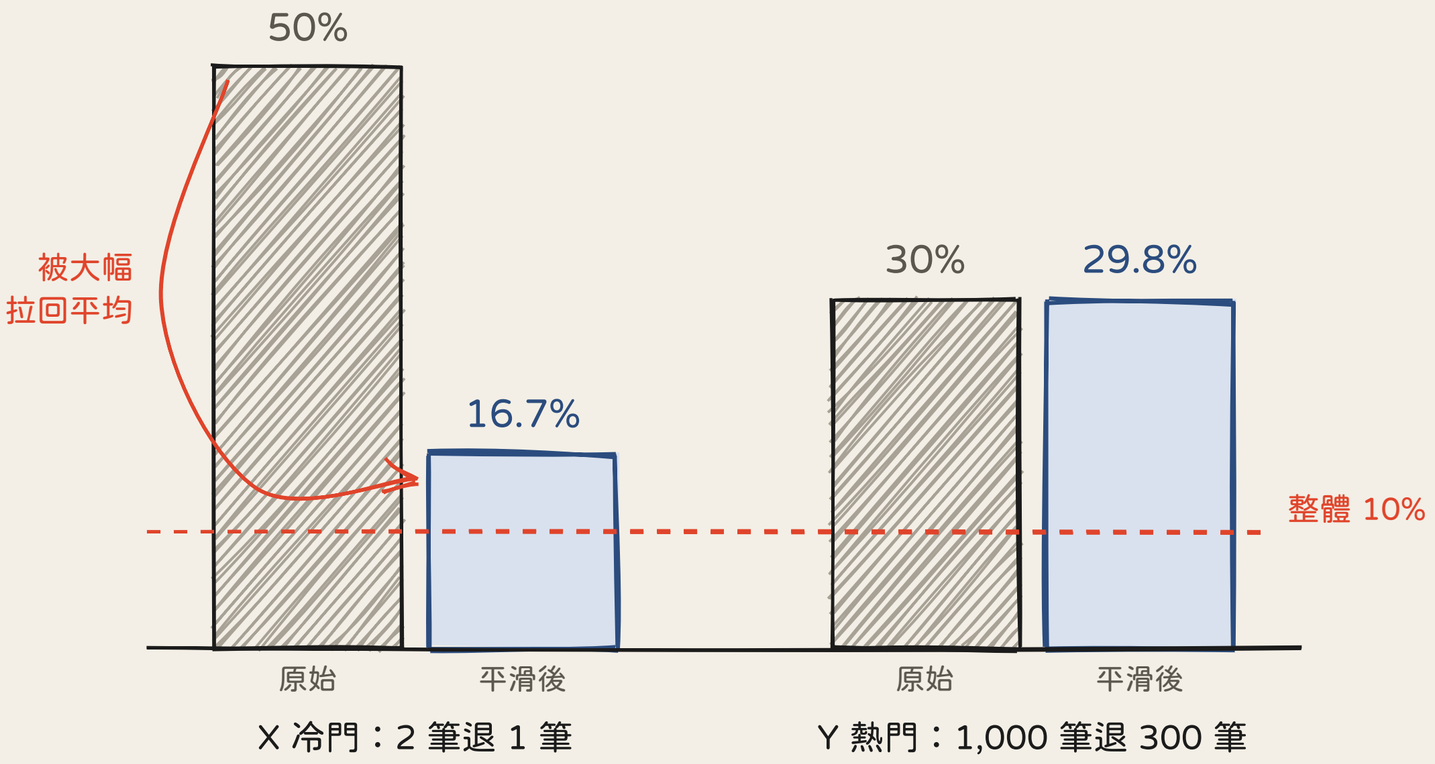
錯誤：直接算 A = 2/3 填回每一列，訂單 1 的 2/3 裡含有它自己的答案

驗證集與上線：改用整份訓練資料算出的對照表 A = 2/3、B = 1/3

怎麼讀：每一橫列是一筆要編碼的訂單，藍格是它被允許看的答案；對角線的叉永遠空著——自己的答案不准進自己的特徵。

平滑：樣本少，就別太相信它

賣過 2 次、退了 1 次，退貨率 50%——很可能只是運氣。



平滑後 =
（該類退貨數 + m × 整體退貨率）
÷（該類訂單數 + m）

m = 10：先假設每一類都有 10 筆「平均水準」的虛擬訂單。

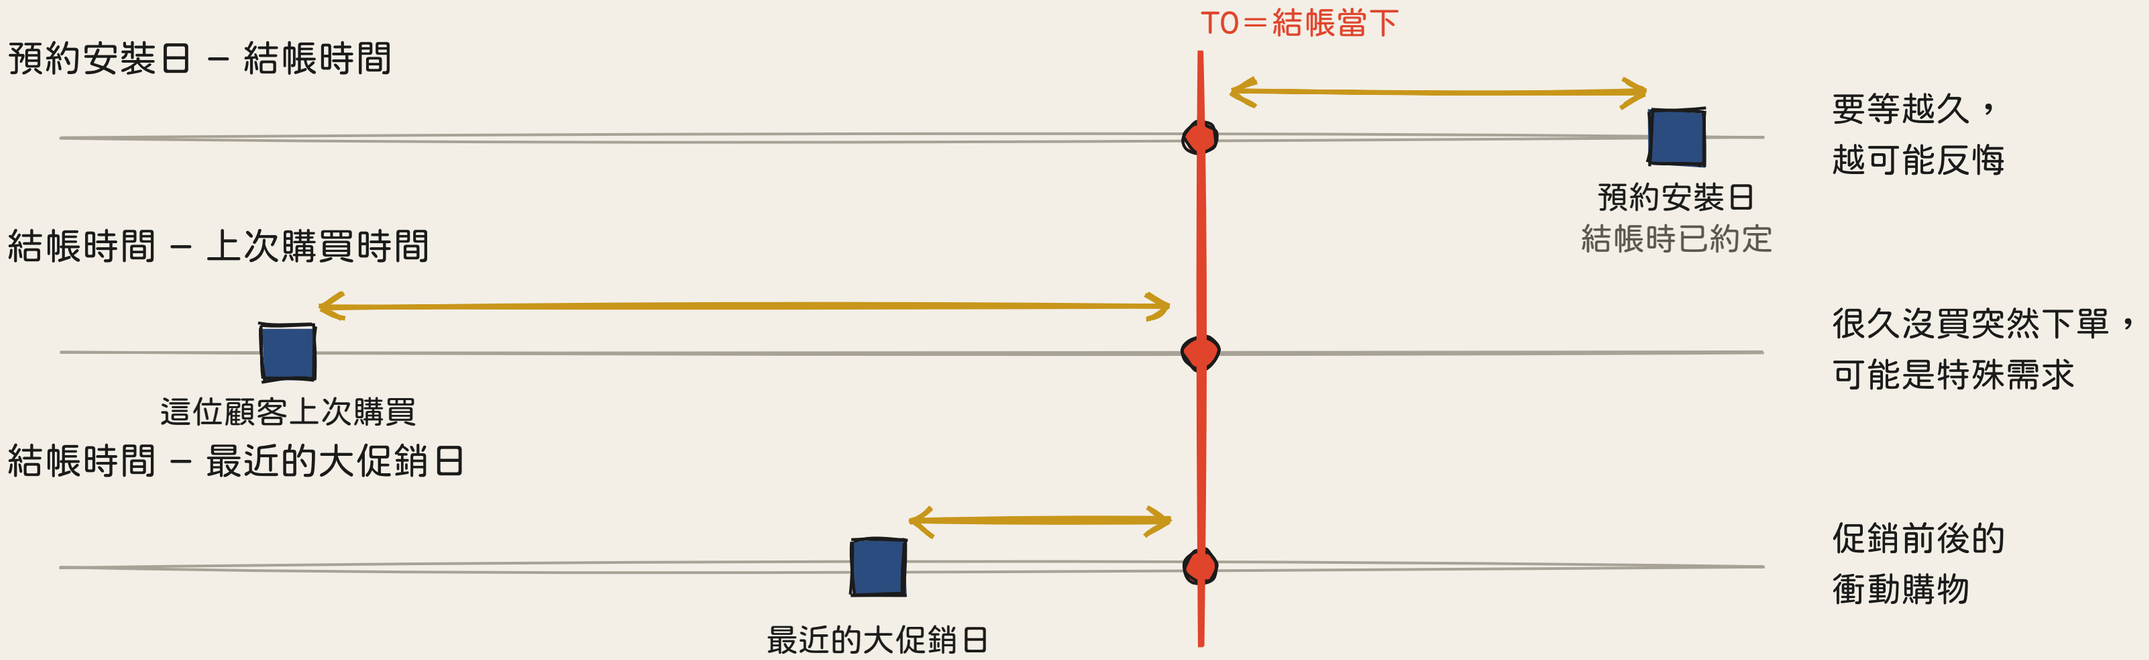
X：(1 + 10×0.1) ÷ 12 = 16.7%
Y：(300 + 1) ÷ 1,010 = 29.8%

資料越多，
越相信它自己的數字。

怎麼讀：比較兩組「灰柱 → 藍柱」的落差：冷門商品從 50% 掉到虛線附近，熱門商品幾乎不動——平滑只修正樣本少的那一類。

時間差：兩個已知時點相減

時間點本身看不出意義；兩個 T0 已知的時間點相減，通常最有力。



危險：「年份」「累計下單次數」會一直變大，上線時全是模型沒見過的值（分布漂移）。
改用比率（退貨次數 ÷ 購買次數）或「近 90 天」視窗。

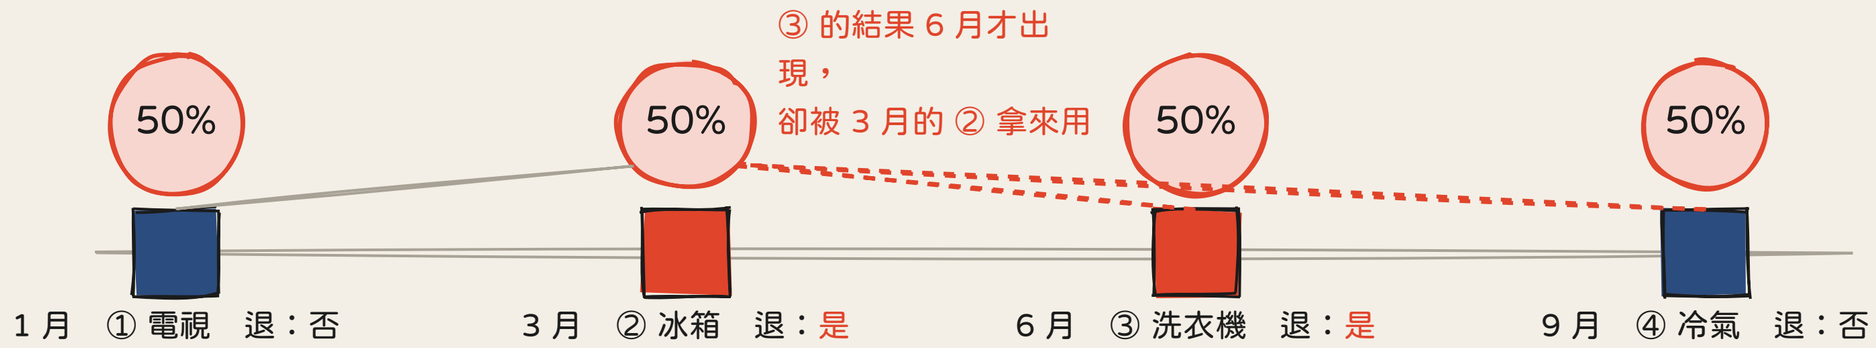
怎麼讀：朱紅直線是結帳那一刻；每一列的黃色雙箭頭就是一個特徵——兩端都必須在 T0 當下已經知道。

歷史特徵：只用當時已經知道的

小陳的 4 筆訂單，特徵「這位顧客的退貨率」——兩種算法。

偷看未來

用整份資料算，
每筆都填 2/4



時點正確

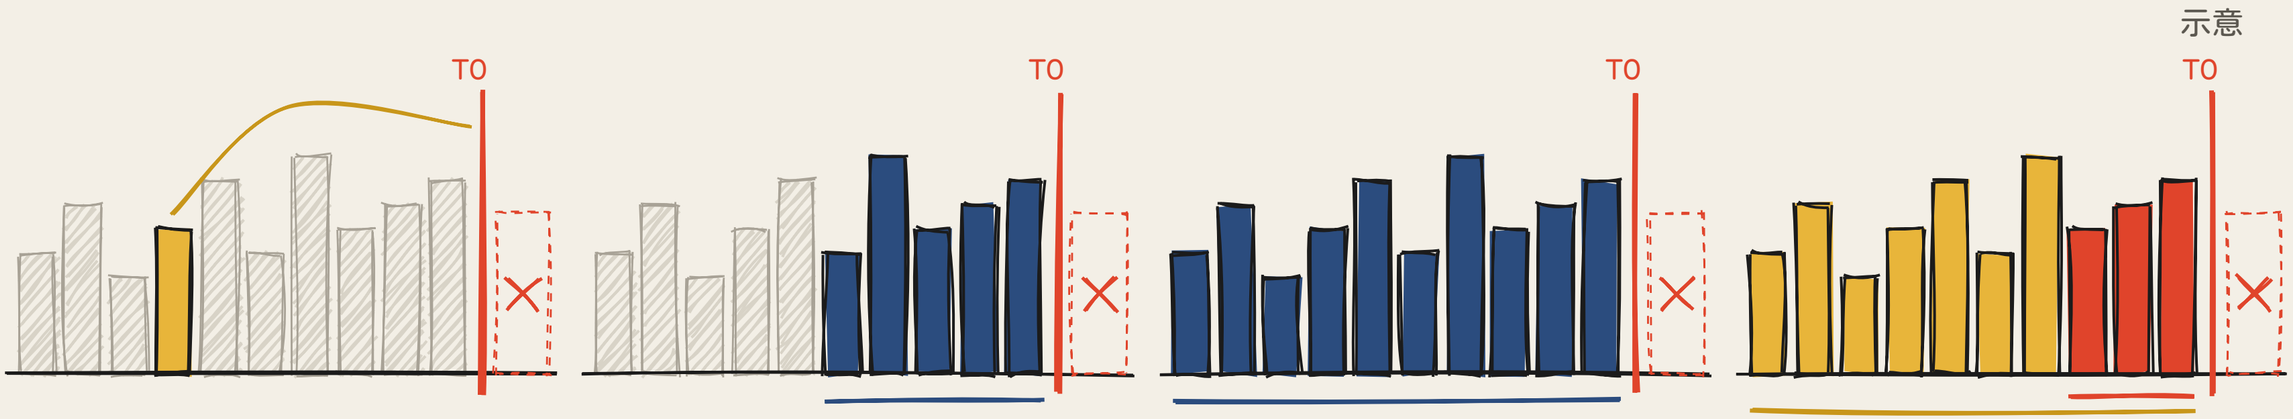
只用 T0 前已知、
排除自己



怎麼讀：上排每個圓都是 50%，② 用到了未來（朱紅虛線）；下排數字隨時間長出來——看「結果何時被知道」，不是「事件何時發生」。

序列資料的四種歷史特徵

同一串過去的紀錄，四種「回頭看」的方式；每一種都只能看 T0 左邊。



落後值（lag）

往前看第 k 期的值

例：上週同一天的銷量

k 必須 ≥ 預測距離：要預測 7 天後，就不能用昨天

滾動統計

過去一段時間的
平均、次數、最大值

例：過去 30 天的平均消費

視窗只含 T0 之前，不含當天

累計統計

從頭到現在的累計

例：到目前為止的退貨率

用比率，不用次數（避免漂移）

變化量

近期和長期比較

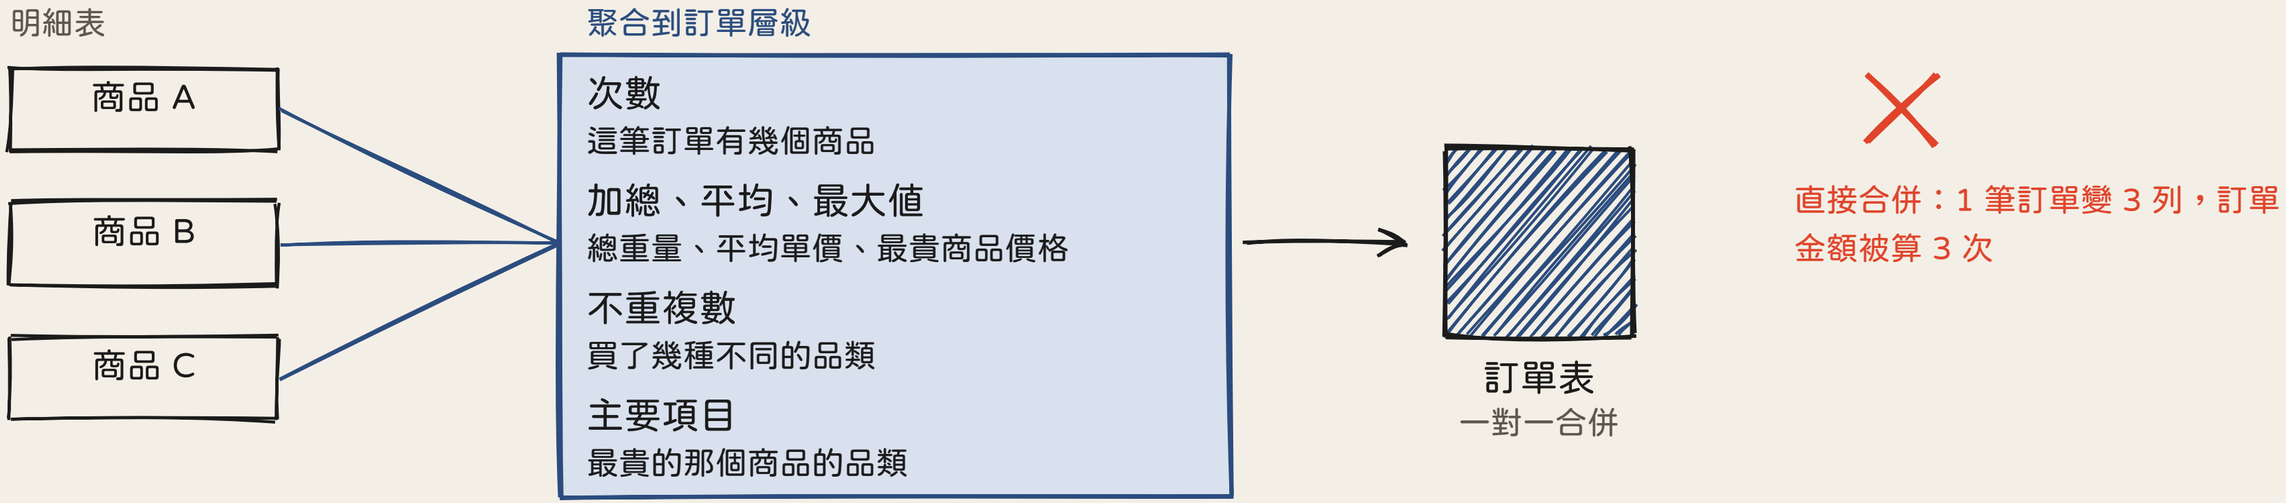
例：近 30 天消費 ÷ 近 365 天月平均

用來抓「最近變了」

怎麼讀：四張小圖都是同一串紀錄，有顏色的柱子是這個特徵實際用到的部分；朱紅線右邊的，一根都不准碰。

多表：一對多，先聚合再合併

明細表一列一個商品；先把它收成「一筆訂單一列」，才能和訂單表對上。



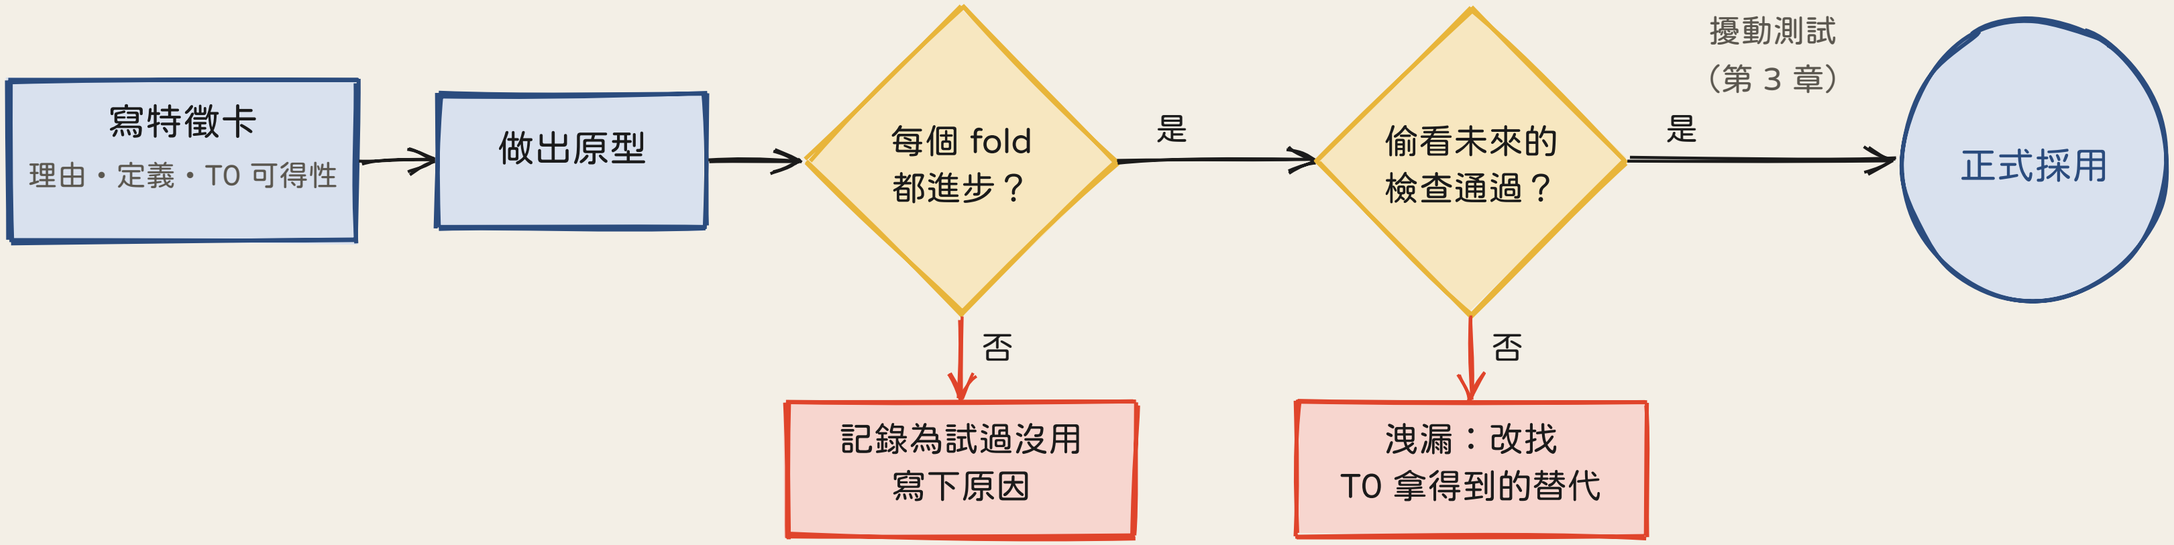
文字：先做便宜的——字數、備註有沒有「送禮」；需要再上 TF-IDF、embedding。
結帳時不存在的「退貨原因說明」，絕對不能用。

地理：倉庫到顧客的距離、是否同縣市、區域過去的退貨率（要時點正確）；郵遞區號當高基數類別。

怎麼讀：三個商品方塊先收進一張藍卡，再和訂單表一對一合併；右上的叉是跳過聚合的後果。

一個特徵要過哪些關卡

每一道關卡擋一種錯誤：沒有理由的嘗試、雜訊增益、資料洩漏。





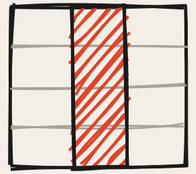
消融實驗

一次只加或拿掉一組，切分、模型、參數全部固定



邊際價值

已有「過去退貨率」，再加「過去退款金額」——重疊太多，沒有幫助



置換重要度

在驗證集上打亂一欄，看分數掉多少

怎麼讀：從左上的特徵卡往右走，兩個菱形各擋一種假進步；往下掉的也要寫成紀錄，否則下一次會有人再試一次。

資料型態 × 處理方式

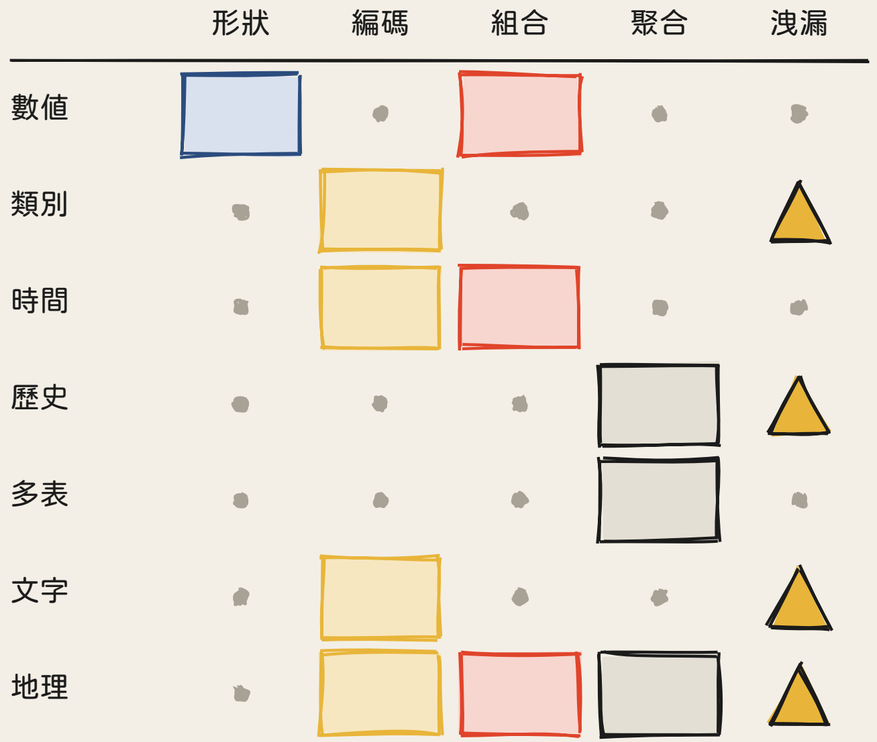
先找到欄位屬於哪一列，往右看該做什麼；有三角的，做完一定查洩漏。

	形狀轉換	編碼	組合・差值	聚合	洩漏風險
數值	補值＋旗標、log、截尾、標準化	·	比率、差值	·	·
類別	·	one-hot；高基數用次數、OOF 目標編碼＋平滑	·	·	▲
時間	·	拆分量、週期 sin / cos	時間差（最有力）	·	·
歷史	·	·	·	落後、滾動、累計、變化量（時點正確）	▲
多表	·	·	·	先聚合到訂單層級再合併	·
文字	·	字數、關鍵字 → TF-IDF、embedding	·	·	▲
地理	·	郵遞區號＝高基數類別	距離、是否同縣市	區域退貨率（時點正確）	▲

怎麼讀：每一列是一種資料型態，有色格是主要做法；歷史、多表與目標編碼是最有力也最容易出錯的地方。

第 4 章小結

- 表格資料上，好特徵通常比換模型有效：把業務知識翻譯成欄位
- 前處理配合模型：樹只看順序，不必縮放；線性直接乘權重，要縮放與轉形狀
- 高基數目標編碼：一定做 out-of-fold 與平滑，否則就是洩漏或過信小樣本
- 歷史特徵要時點正確：只用 T0 前「已被觀察到」的事件、排除自己；新對象給整體平均，不給 0
- 判斷價值：一次加一組、看邊際價值、每個 fold 都進步、在驗證集看置換重要度

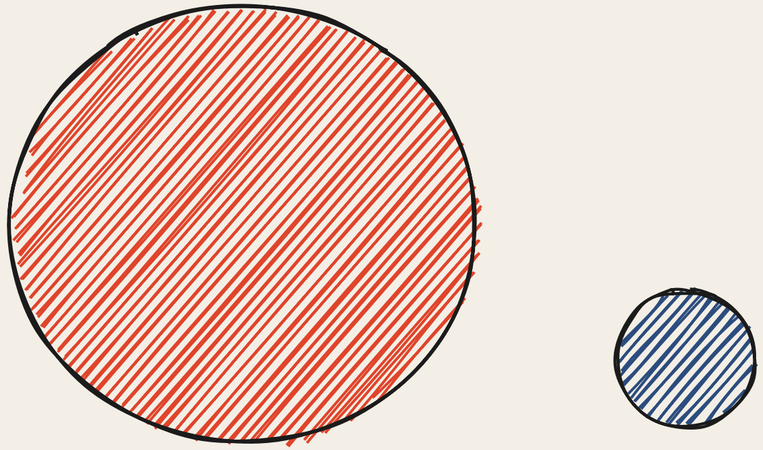


下一章：模型選擇與評估

第 5 章

模型選擇與評估

模型是畫龍點睛：先有基準，再談升級。
在表格資料上，換模型帶來的進步，
通常小於一個好特徵。



學習目標

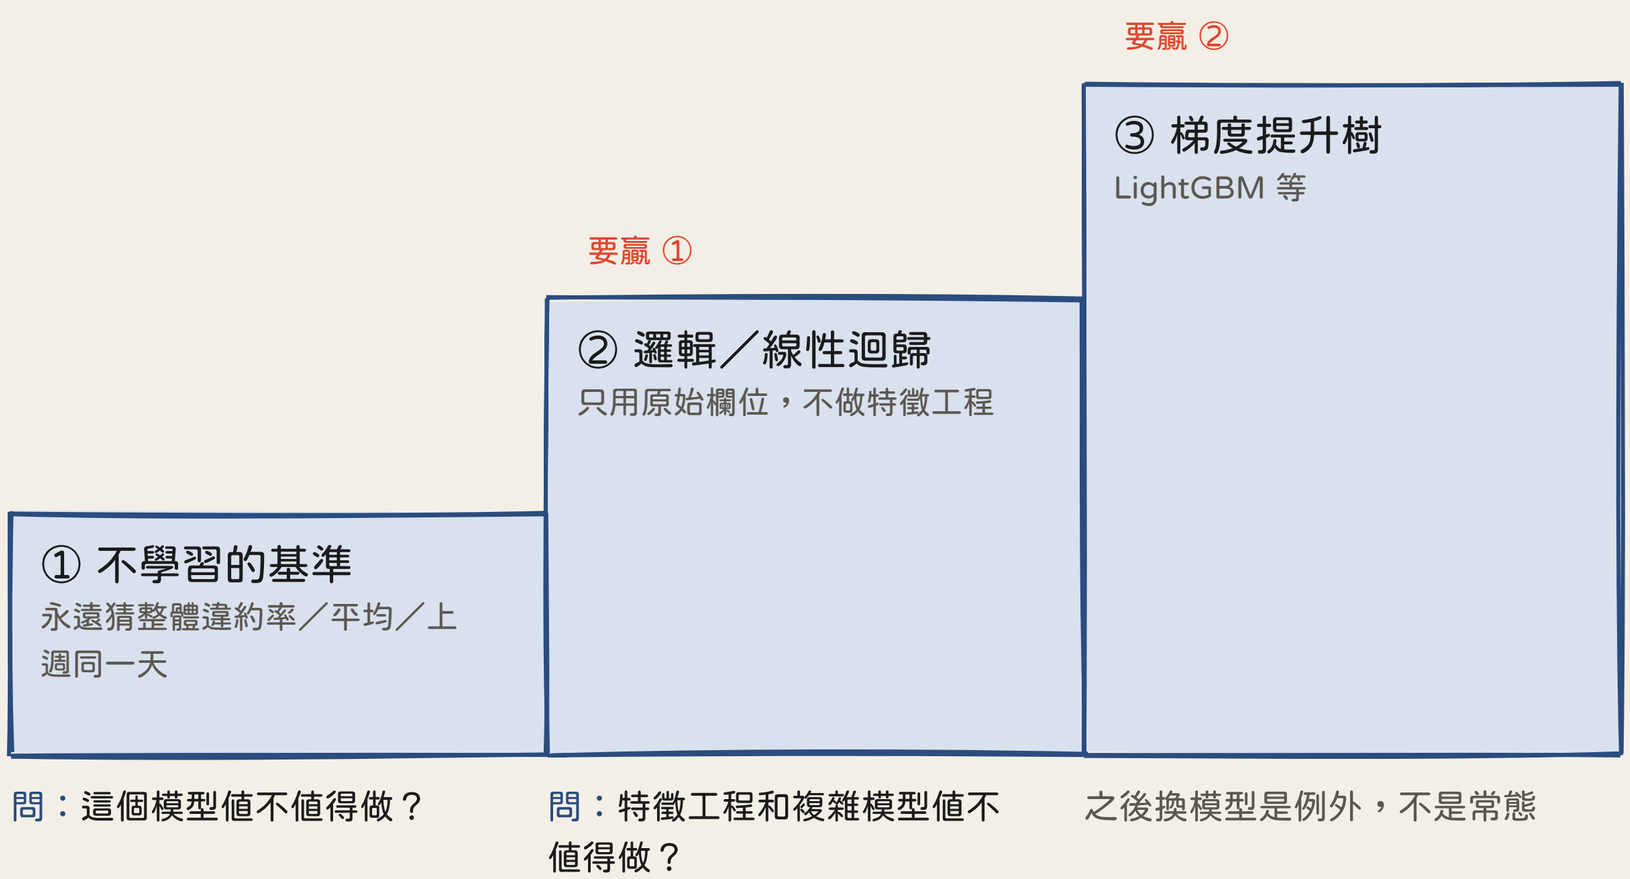
- 說明為什麼一定要從基準開始，並建立兩種基準
- 用直覺說明線性、決策樹、隨機森林、梯度提升樹、表格基礎模型怎麼運作
- 依資料規模、特徵型態、解釋需求與部署限制選模型
- 設計公平比較，用過擬合差距與校準檢查可用性

本章案例：銀行信用卡審核

審核當下（T0）預測申請人 12 個月內會不會違約。
約 8,000 筆歷史申請、30 個欄位；
主管機關要求每一筆拒絕都要能說明理由。

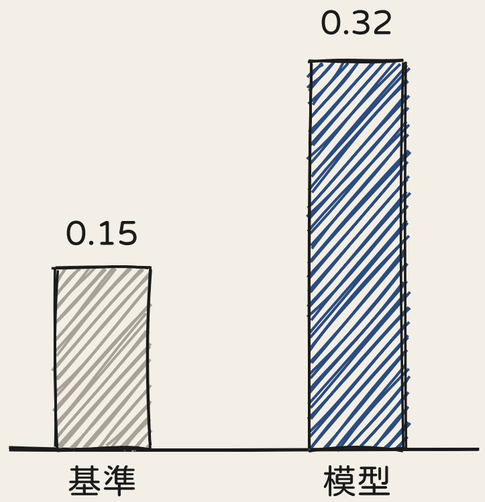
先有基準，再一階一階往上爬

每往上一階，都必須穩健地贏過下一階，才值得它帶來的複雜度。



0.32 是好是壞？

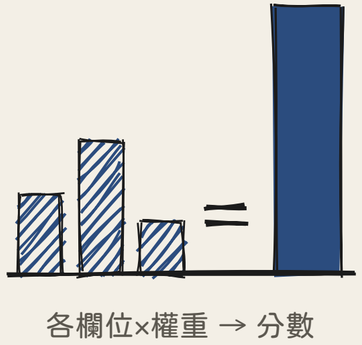
違約率 15% 時，不學習的基準 PR-AUC 約 0.15。



怎麼讀：由左下往右上。② 贏不了 ①：資料可能沒訊號，回頭查問題定義；③ 贏不了 ②：留在簡單模型。

每種模型，用不同方式思考

不談數學，只看直覺：它把欄位變成預測的方法。



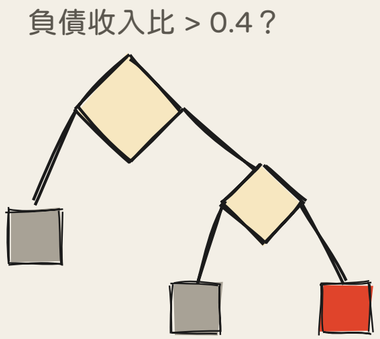
各欄位×權重 → 分數

加權總和

線性／邏輯迴歸

像評分表，每項幾分、加起來

容易解釋

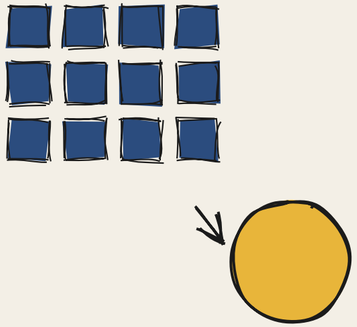


是非題

決策樹

像醫生問診流程圖

一棵樹不穩定

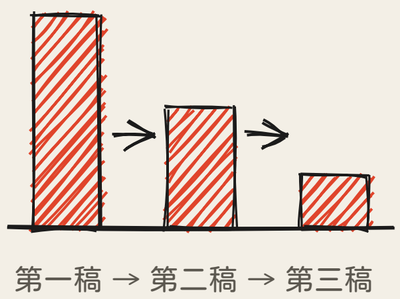


投票

隨機森林

問 500 位專家取多數

穩、少調參



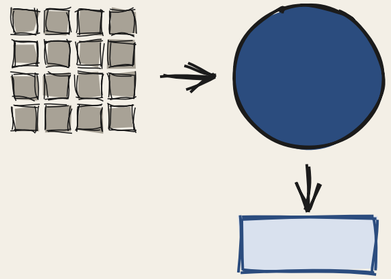
第一稿 → 第二稿 → 第三稿

接力修正

梯度提升樹

作文一稿一稿改

表格資料的預設強者



預訓練通才

表格基礎模型

做過上百萬題的考生

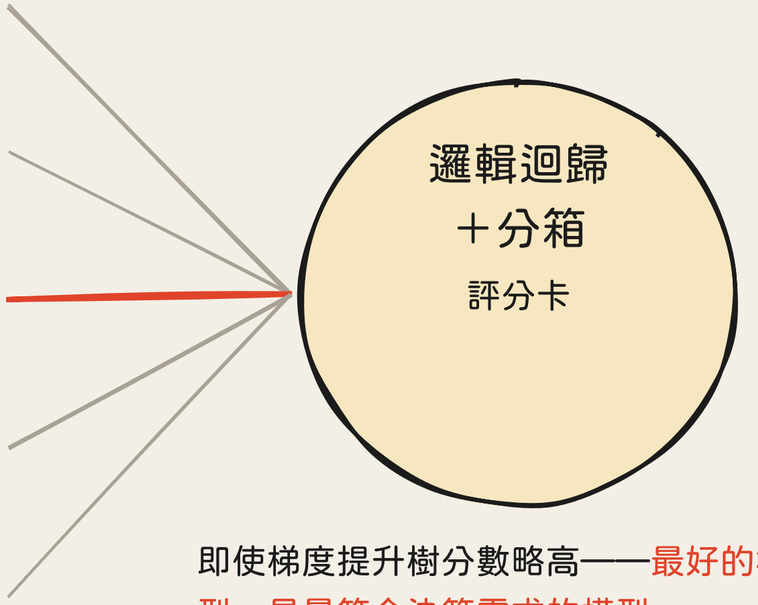
小資料免調參

怎麼讀：每格上方的圖就是那個模型的「動作」；記住五個詞——加權總和、是非題、投票、接力修正、預訓練通才。

讓問題的條件幫你選模型

本章例子：銀行信用卡審核，五個問題逐一回答。

	問題	本章例子的答案
▨	資料有多少列、多少欄？	8,000 列、30 欄，屬於小資料
▨	欄位是什麼型態？	多為數值
■	需要解釋到什麼程度？	法規要求說明拒絕理由
▨	部署有什麼限制？	批次審核，速度不是問題
▨	要排序還是機率？	用機率訂額度，需要校準



即使梯度提升樹分數略高——最好的模型，是最符合決策需求的模型。

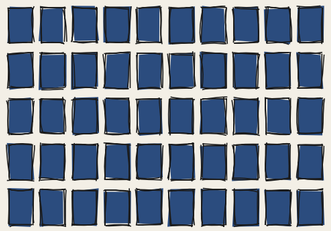
怎麼讀：五條線匯向右邊的圓；決定性的是朱紅那一條——解釋需求一票就決定了答案。

公平比較：一次只換一樣

「梯度提升樹 0.32，比邏輯迴歸 0.29 好」——但兩邊同時改了太多東西。

不公平的比較

梯度提升樹



50 個特徵



調參一整天

0.32



差距來自模型？特徵？調參？說不出來

邏輯迴歸



10 個原始欄位



沒有調參

0.29

公平比較的條件



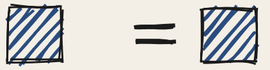
相同的資料切分
同樣幾次考試（fold）



相同的特徵
要比模型，就只換模型



對等的調參預算
不能一個調一天、一個用預設

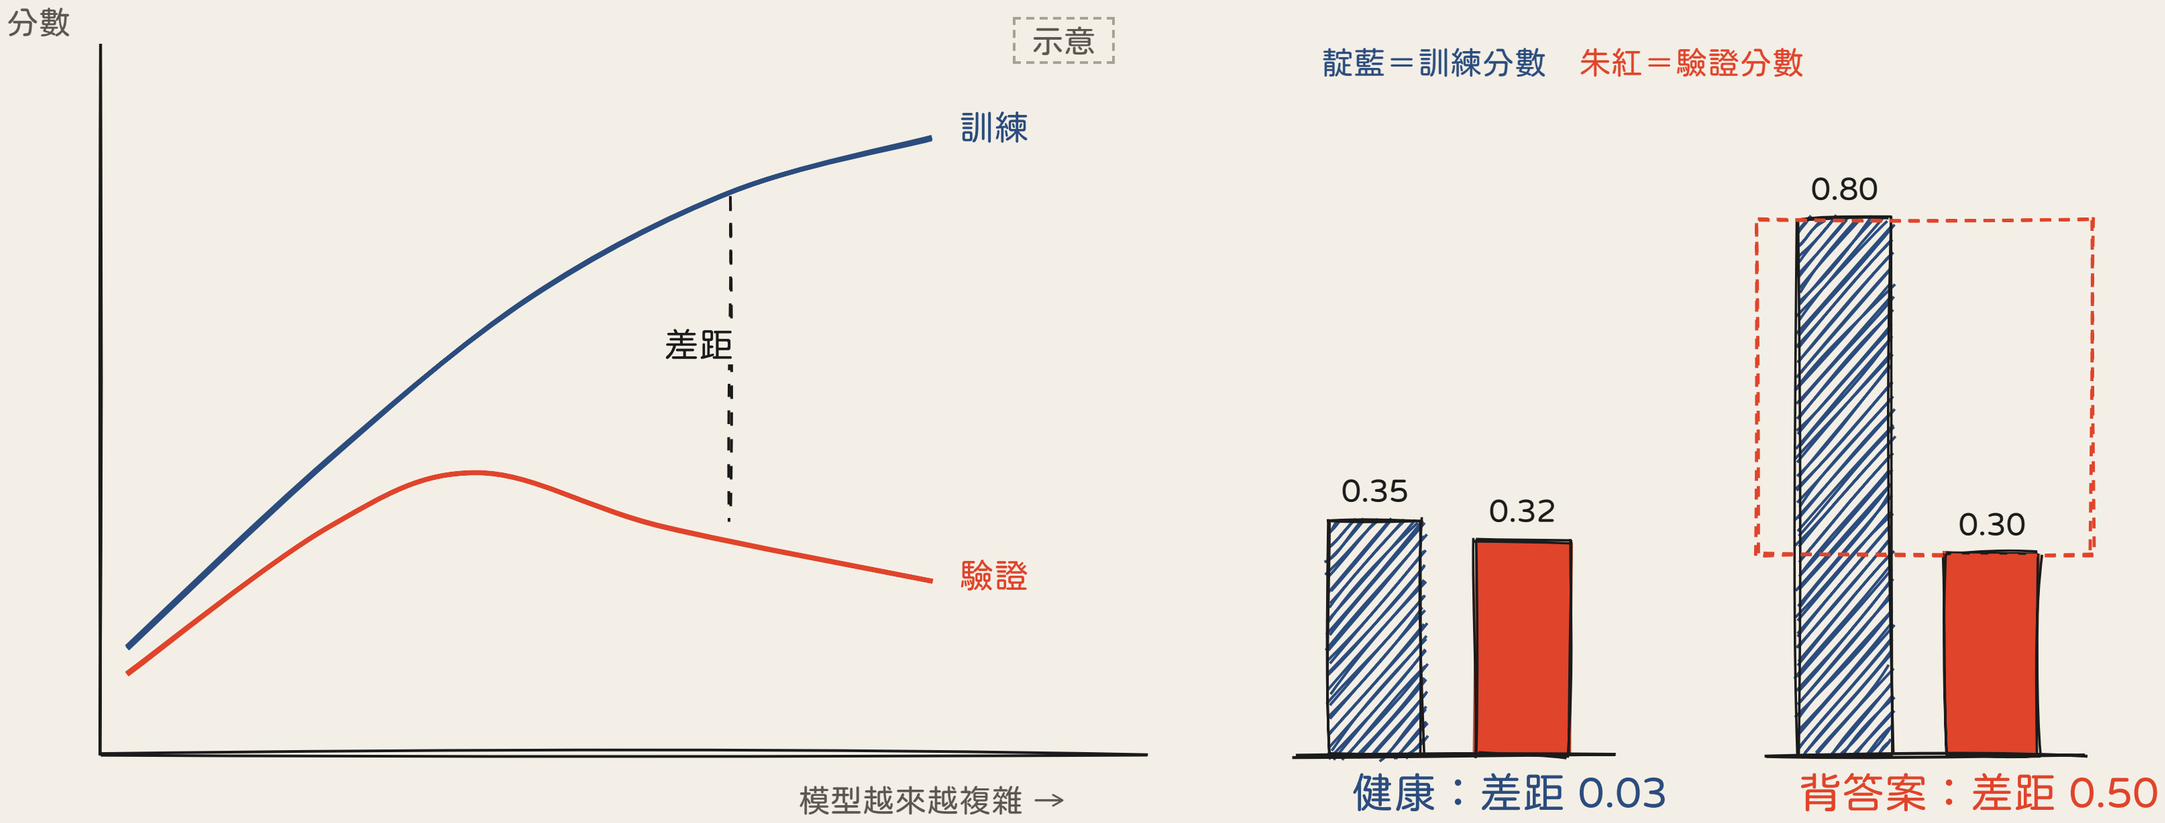


同 fold 配對比較
每一次考試都贏，不只平均高

怎麼讀：左邊兩列的方塊數和時鐘都不一樣，分數差無法歸因；右邊每一列左右兩個圖示一模一樣，只剩模型不同。

過擬合差距：學規律，還是背答案？

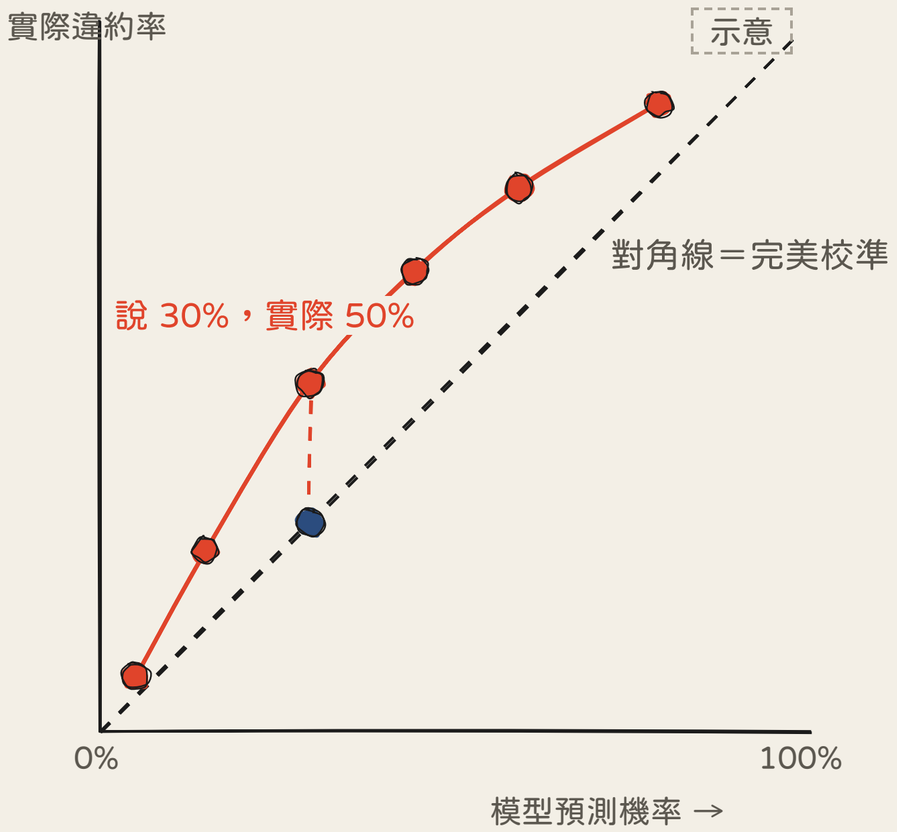
過擬合差距＝訓練分數 − 驗證分數。差距大，代表模型把訓練資料的雜訊也背了下來。



怎麼讀：左圖兩條線分開的地方就是背答案的開始；換模型時，驗證分數只高一點、差距卻大很多，這個進步通常不穩定。

校準：模型說 30%，真的是 30% 嗎？

排序準不代表機率準：它說 30% 的那群人，實際違約率可能是 50%。



怎麼檢查

依預測機率分成 10 組，比每組「平均預測機率」和「實際違約率」

怎麼修正

Platt scaling 或 isotonic regression，把輸出轉換到貼近實際比例

什麼時候需要？



直接用機率數值

訂價、額度、預期損失

→ 需要校準



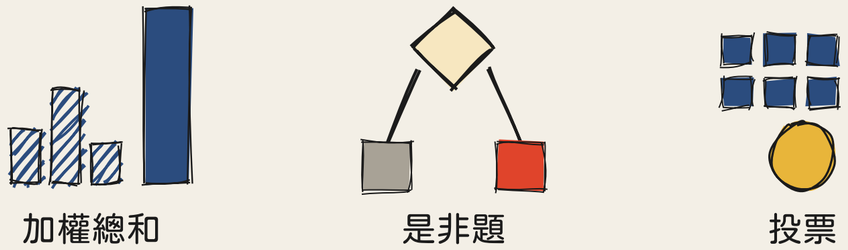
只排序取前幾名

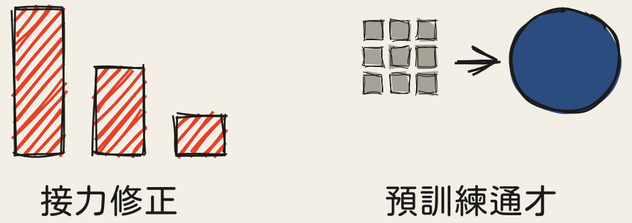
排序正確就夠了

怎麼讀：點落在對角線上＝說幾 % 就真的幾 %；偏離越遠，機率數字越不能直接拿去訂額度。

第 5 章小結

- 先建立兩種基準：不學習的基準（值不值得做模型）與簡單模型基準（值不值得做複雜的事）
- 線性＝加權總和、決策樹＝是非題、隨機森林＝投票、梯度提升樹＝接力修正、表格基礎模型＝預訓練通才
- 表格資料預設選梯度提升樹；但最符合決策需求的模型才是最好的
- 公平比較：相同切分、相同特徵、對等調參，同 fold 配對比較
- 看過擬合差距；要用機率數值時，檢查校準



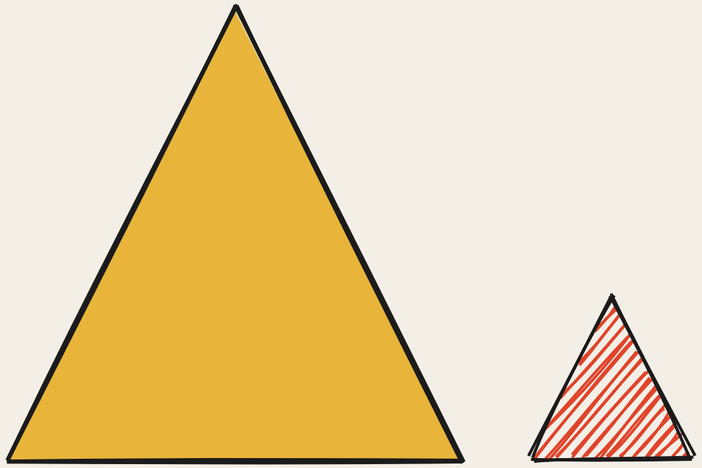


下一章：人機協作的資料科學

第 6 章

人機協作的資料科學

AI 讓實驗變便宜，所以判斷哪個結果可信，成為人類最有價值的能力。



學習目標

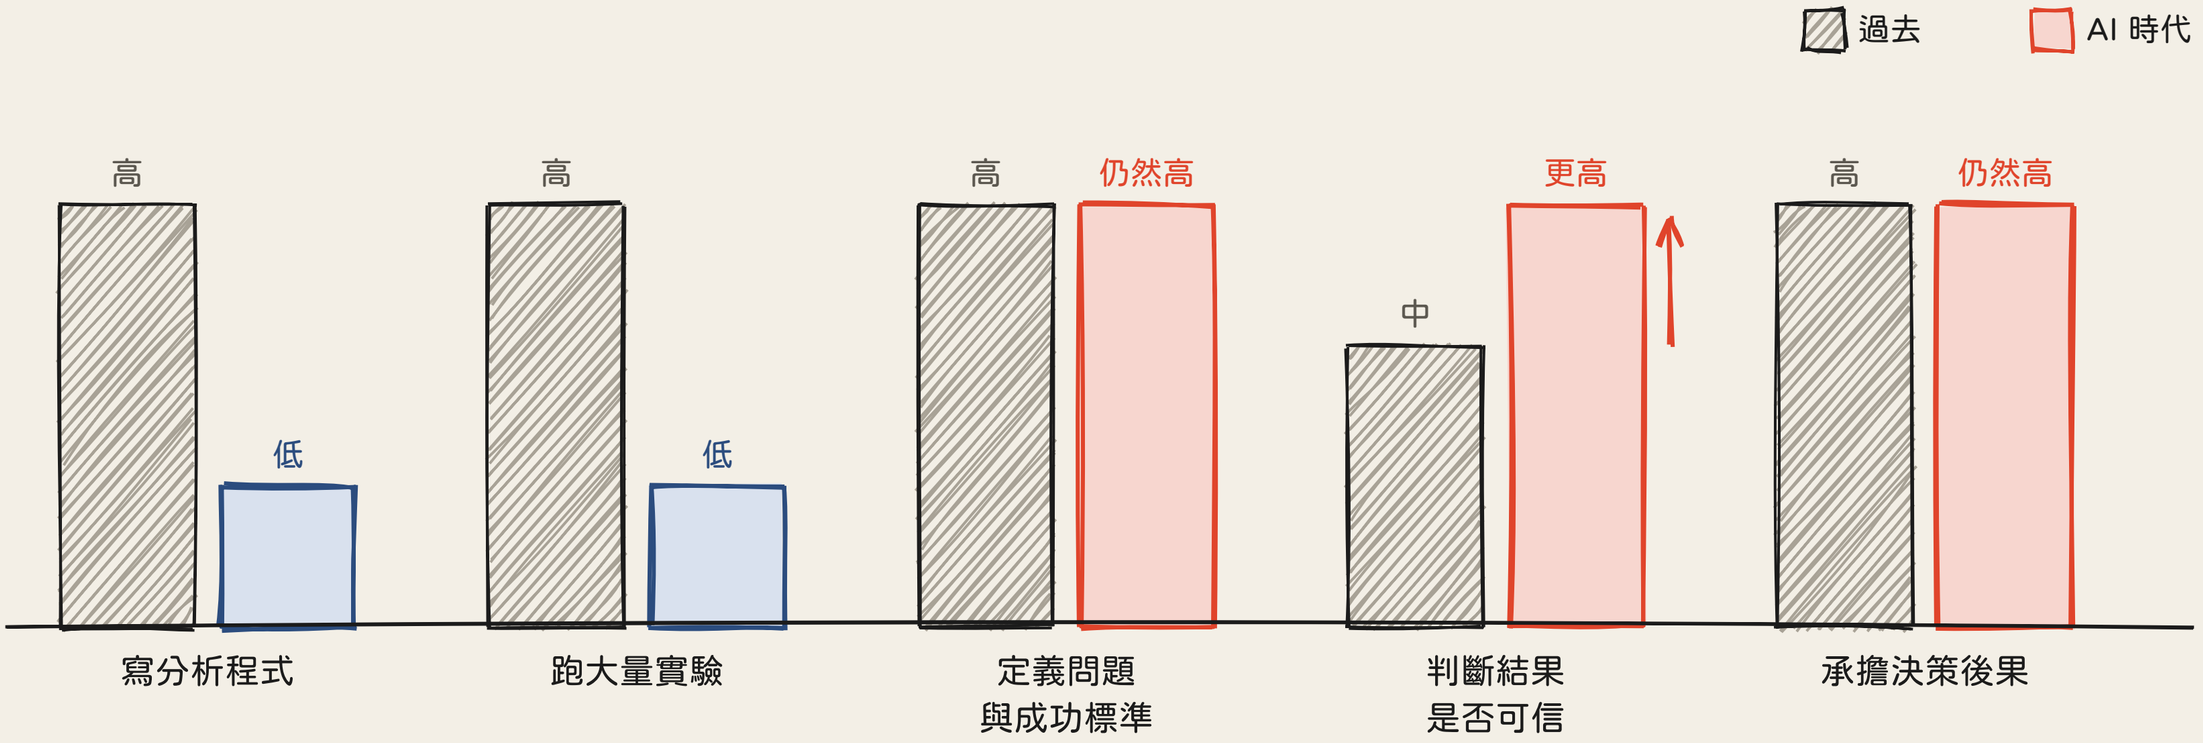
- 說明 AI 如何改變成本結構，人的時間該移到哪裡
- 辨識「合理但錯誤」的失敗模式，說出它為何危險
- 劃分人與 AI 的責任，指出必須由人決定的時點
- 用驗收思維審查 AI 產出的分析結論

本章案例

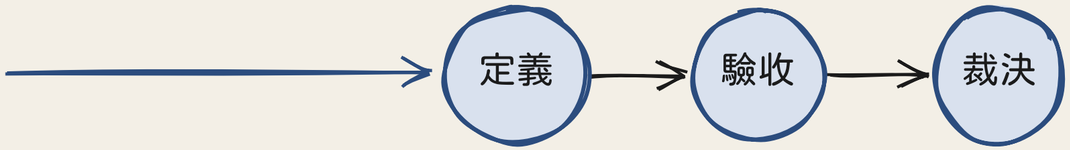
分析師小林請 AI 預測下個月會流失的會員。AI 一個下午跑了 40 個實驗，回報 PR-AUC 從 0.21 提升到 0.38——能相信嗎？

成本結構的轉移

做出來變便宜了；定義、判斷、承擔的成本沒有變，甚至更高。



瓶頸從「做得出來」移到「判斷得出來」——人的時間移到



怎麼讀：每組左灰右彩：前兩組（執行）整根縮下去，後三組（判斷與責任）留在高處——要看的結果變多，判斷的負擔反而變重。

「合理但錯誤」長什麼樣子

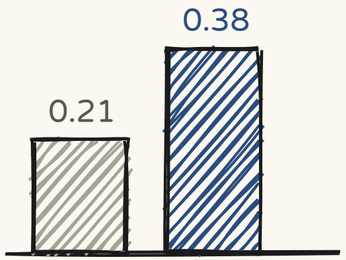
程式不報錯、分數漂亮、文字通順——但結論建立在錯的前提上。

AI 回報

PR-AUC 0.21 → 0.38

主要貢獻：會員最後一次來店距今天數

- ☑ 程式能執行
- ☑ 分數大幅進步
- ☑ 說明文字通順
- ☑ 附了漂亮的圖



「今天」是哪一天？

這段＝「之後三個月都沒來」＝流失的定義

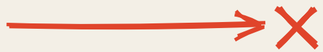


預測當下
三個月前的 T0

資料集最後一天
被當成「今天」



程式錯誤：程式停下來，
你一定會發現

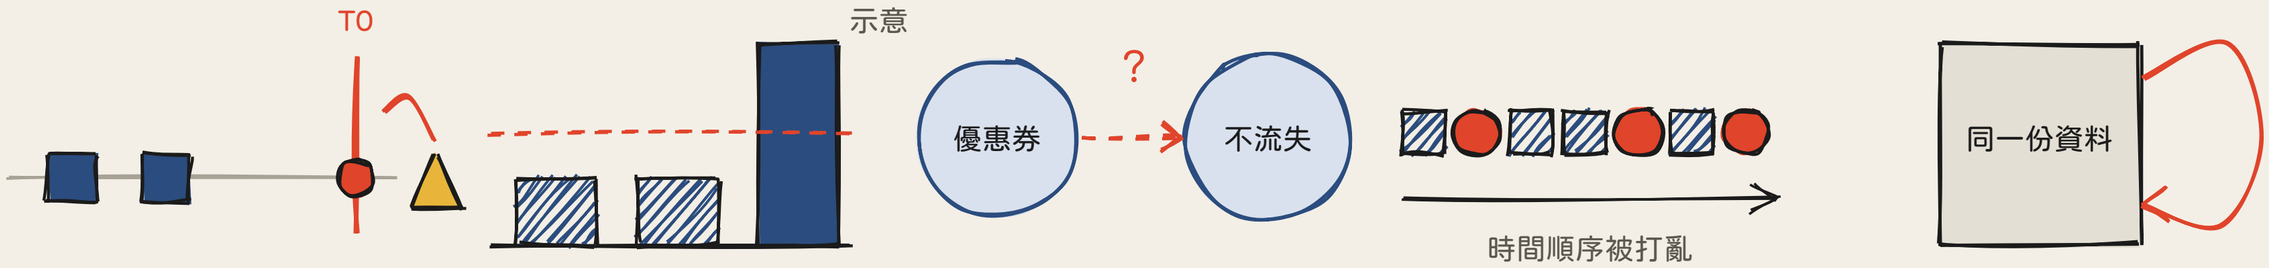


合理但錯誤：一路通過，
直到上線後才崩盤

怎麼讀：左邊的報告每一項都打勾；右邊把那個被圈起來的詞攤開——模型等於拿答案來猜答案，而且沒有任何地方會報錯。

「合理但錯誤」的五種型態

程式不會報錯，只能靠正確的驗證設計（第 3 章）和懂業務流程（第 1 章）抓出來。



使用未來資訊

特徵用到預測當下
還不知道的事

例：用資料集最後一天計算「距今天數」

只看平均

平均進步，
只在某一次考試有效

例：三個月中只有一個月進步很多

相關當因果

把預測力強的變數，
當成可介入的原因

例：常用優惠券的人不流失 → 多發優惠券就能留人？

錯誤的驗證設計

驗證方式沒有
模擬上線情境

例：預測未來，卻用隨機切分

自我說服

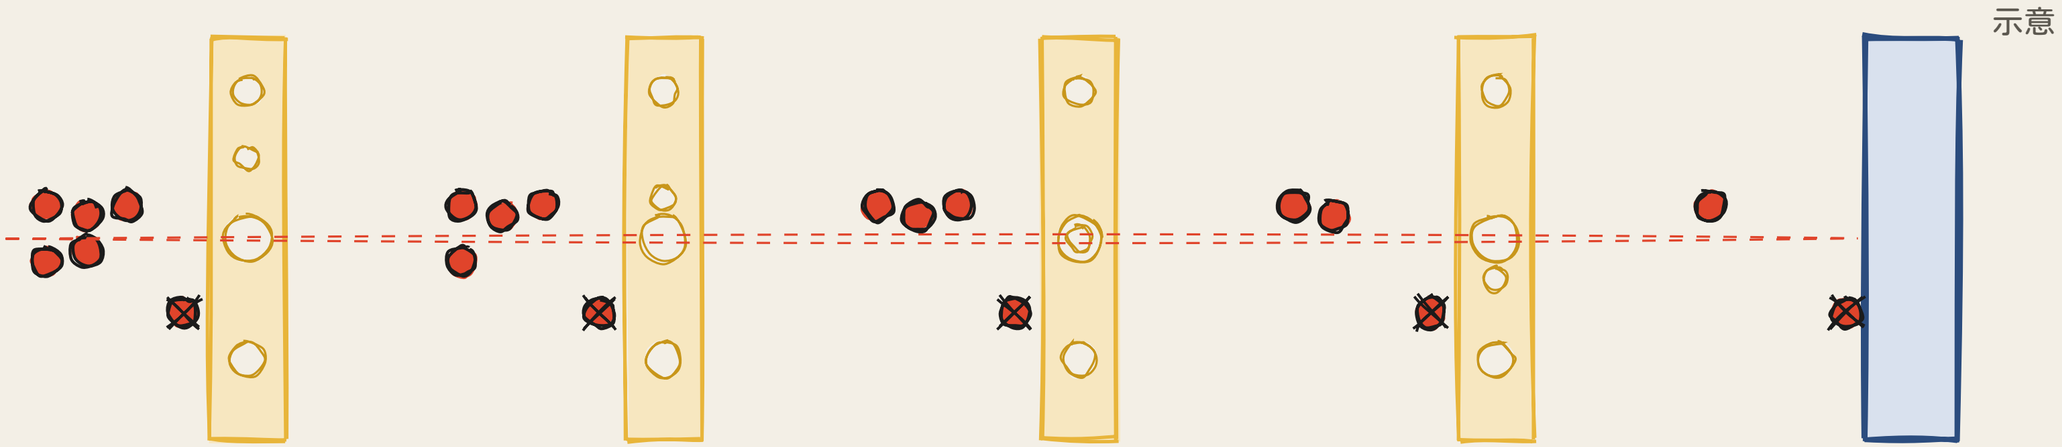
用同一份資料發現模式，
又用它證明模式

例：在全部資料上挑出最好的特徵，再用同一份驗證

怎麼讀：五張小圖各是一種錯法，下方紅框是小林案例裡可能長的樣子；它們的共同點是「看起來都很合理」。

規範制度化：疊好幾層防線

口頭提醒靠「記得」，不可靠；把規則變成會自動執行的機制，每一層擋不同的錯。

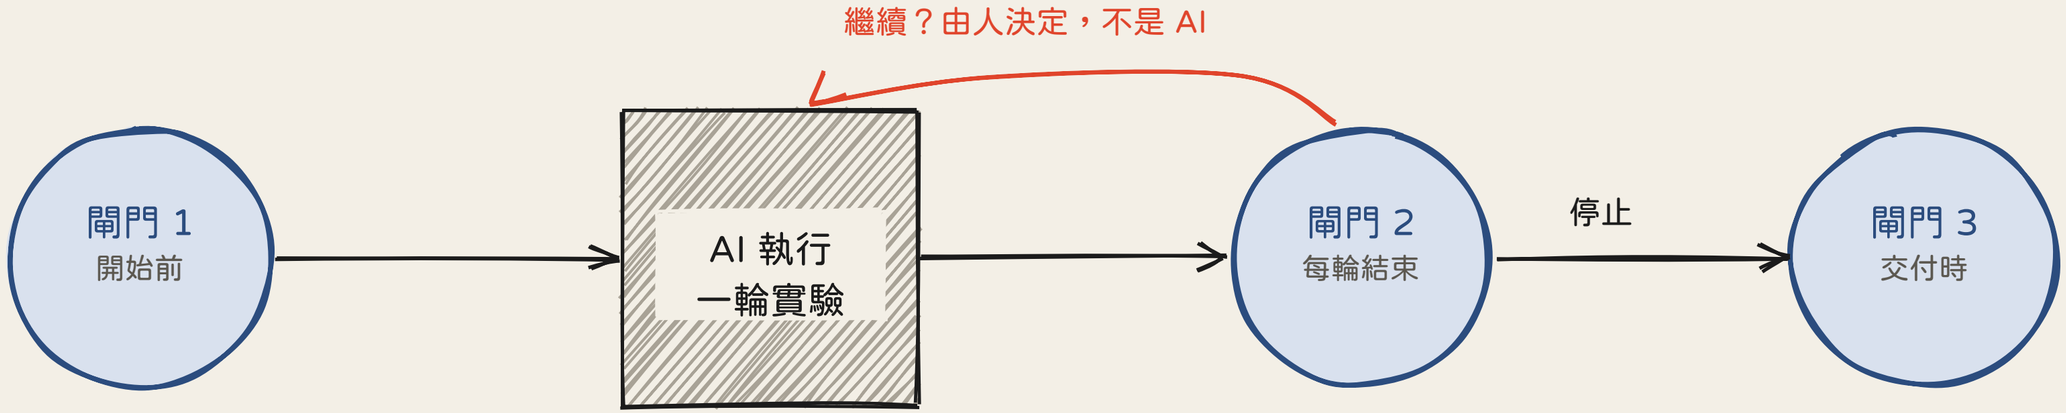


	書面規範	權限控制	自動測試	獨立審查	人類裁決
擋得住	預設的錯誤行為	越界的操作 （讀答案、改原始資料）	已知類型的錯誤 （擾動測試等）	不穩健的增益、 可疑的大幅進步	以上所有的 漏網之魚
擋不住	遺忘或誤解	邏輯上的錯誤	驗證設計本身的錯誤	業務目標本身錯了	—

怎麼讀：錯誤由左往右穿過起司的洞，每一層攔下一部分；最後一層沒有洞——必須是人，因為只有人能判斷業務目標合不合理。

三個必須由人拍板的閘門

AI 做到這裡必須停下來，由人決定才能繼續。



定義問題

支援什麼決策、預測時點、可用資訊、驗證方式、停止條件

定錯了，後面全部白做

可重複很多輪

寫程式、跑實驗、畫圖都交給 AI

審查

哪些結論值得留下、下一步做什麼、要不要停

涉及成本、風險與優先順序的取捨

上線與否

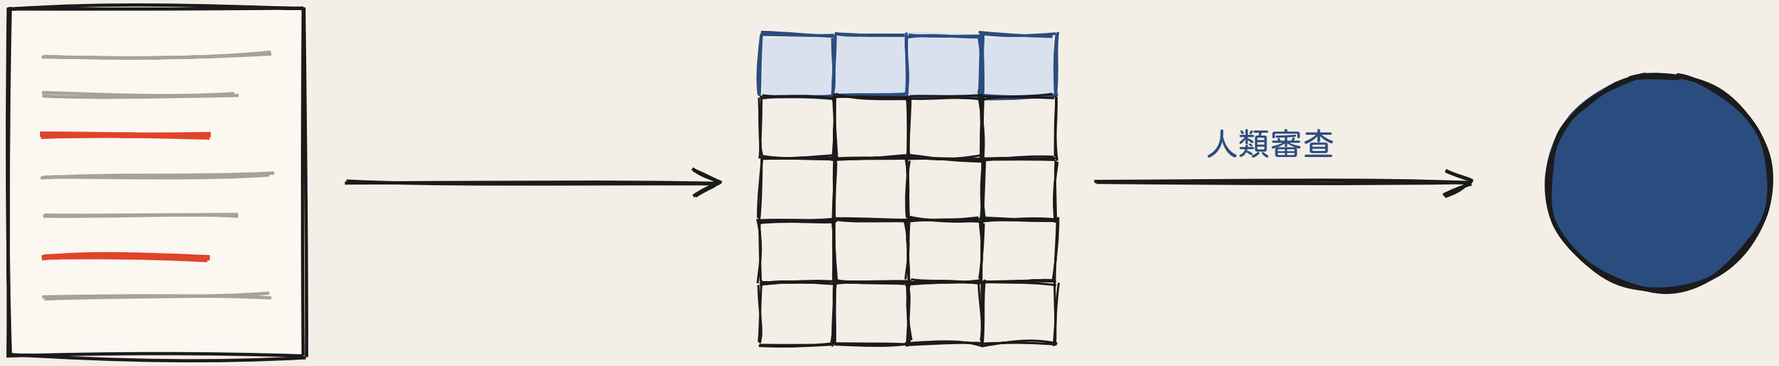
要不要上線、怎麼向決策者說明限制

需要有人承擔後果

怎麼讀：三個圓是人做決定的地方，方塊是 AI 的工作；注意閘門 2 往回的箭頭——是否再跑一輪，是人拍板。

記錄即記憶

AI 沒有跨對話的記憶，人會忘、團隊會換人——唯一可靠的記憶，是寫下來的紀錄。



過程日誌

每次做了什麼、結果、結論，
包含失敗與卡關

避免重做、重踩坑

實驗紀錄

特徵、模型、參數、
每次考試的分數

報告裡每個數字都能追溯

沉澱的結論

經過人類審查、
確定值得留下的發現

下一輪與新成員的起點

為什麼失敗也要記：第二週小林開新對話，AI 又興沖沖提議試「最後一次來店距今天數」——上週已經證明它是洩漏。「這條路不通，原因是 ___」常比成功的結果更省時間。

怎麼讀：由左往右越收越少：日誌記下一切（含紅色的失敗），實驗紀錄留下可追溯的數字，最後只有經過人類審查的結論變成那個圓。

驗收思維：面對「進步了」

沒有預期，看到任何結果都會覺得「嗯，合理」——等於幫 AI 蓋章。

固定問三個問題



預測那一刻，這些值存在嗎？
擋：使用未來資訊
「距今天數」的「今天」是哪一天？



每一次考試都進步嗎？
擋：只看平均
三個月份是不是都進步？



這個結論會改變什麼決定？
擋：有統計意義、沒業務意義
就算準了，客服的挽留做法會不同嗎？

下可驗收的指令

❌ 「幫我做探索分析」

驗證「最近 30 天沒來店的會員流失率較高」，我預期約 2 倍，請依會員等級分層，並附每組樣本數

❌ 「幫我提升分數」

做「會員過去 90 天的來店次數」特徵，和目前最佳組合做同 fold 配對比較

❌ 「這樣有洩漏嗎？」

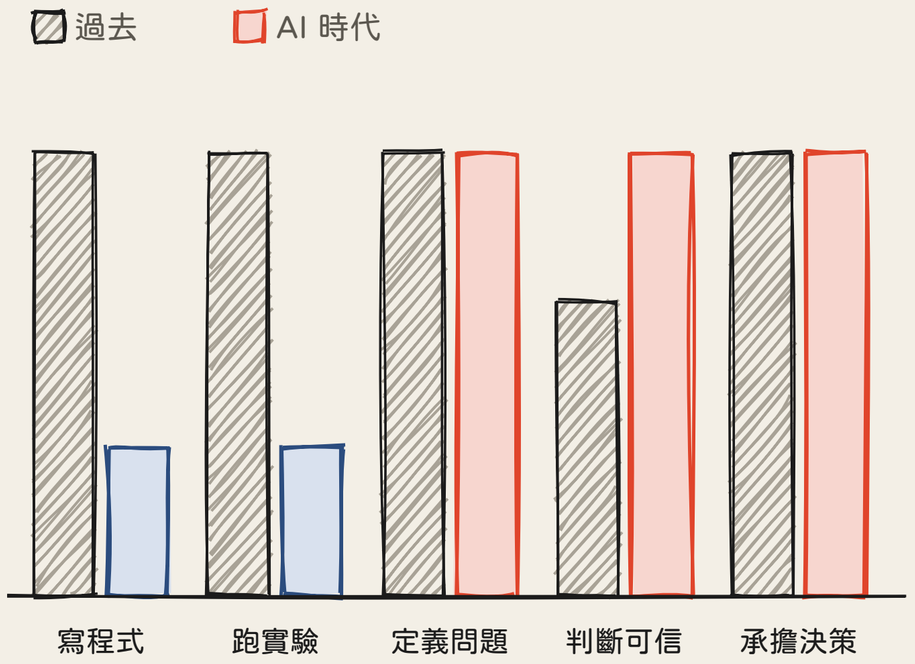
對這組特徵做擾動測試，附上測試輸出

先寫預期，再看結果：開工前寫下「最近 30 天沒來店的會員，流失率大約是其他人的 2 倍」；不符時才會停下來問為什麼。

怎麼讀：左邊三個圓是每次聽到「進步了」都要問的；右邊紅字是模糊指令，藍框是改寫後可驗收的版本。

第 6 章小結

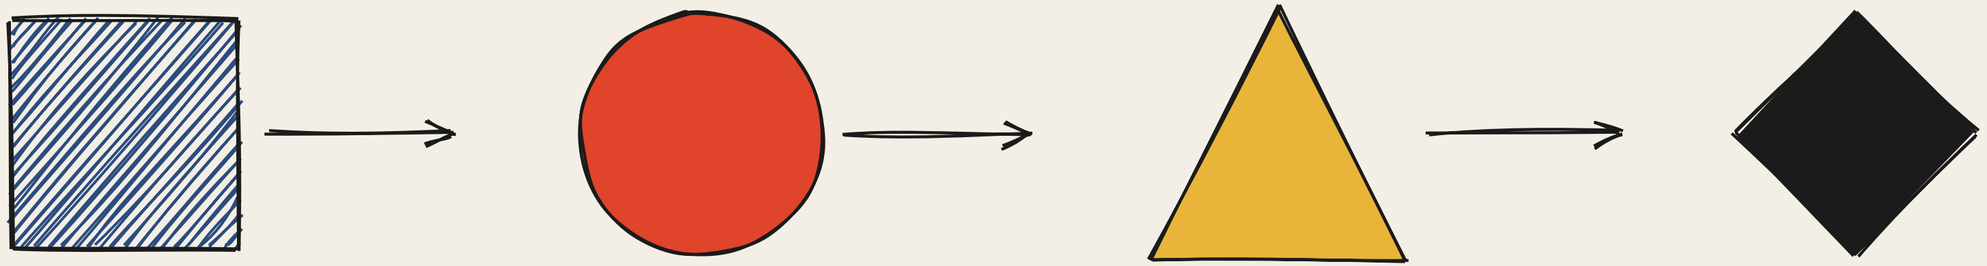
- AI 讓執行成本趨近於零；定義問題、判斷證據、承擔決策的成本不變——人的時間移到定義、驗收、裁決
- 最危險的是「合理但錯誤」：程式能跑、分數漂亮，但前提錯了
- 規範要制度化成多層防線，最後一層必須是人
- 開始前、每輪結束、交付時，是三個由人決定的閘門
- 紀錄是人與 AI 共享的記憶；先寫預期、固定三問、下可驗收的指令



下一章：大總結

大總結：大道至簡

四步依序走；最後一步，交給人來判斷。



問題定對

任務由決策決定；
EDA 為了做決定而看資料

第 1、2 章

切分做對

驗證要模擬上線那一刻：
預測那一刻，這個值存在嗎？

第 3 章

特徵講得出理由

來源假設、T0 拿得到、
邊際真的有增益

第 4 章

模型最後才挑

先有基準，再談升級；
換模型的進步常小於一個好特徵

第 5 章

第 6 章：AI 讓實驗變便宜——判斷哪個結果可信，是人最有價值的工作。

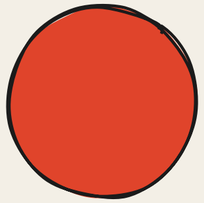
結業三問：你答得出來嗎？



為什麼選這些特徵？

每個特徵都有一張卡：來自哪個假設、預測當下拿得到、加進去每個 fold 都進步。

第 2、4 章



怎麼證明進步不是運氣？

同一個 fold 配對比較，每一次考試都要贏；大幅進步先做擾動測試，排除洩漏。

第 3 章



換一批資料，能重現嗎？

前處理包在 Pipeline 裡、每次比較都有實驗紀錄、保留集只看一次。

第 5、6 章

參考文獻

切分與洩漏

scikit-learn, *Common pitfalls and recommended practices*
scikit-learn, *Cross-validation: evaluating estimator performance*

特徵工程

Kuhn & Johnson, *Feature Engineering and Selection* (2019)
NVIDIA, *The Kaggle Grandmasters Playbook*
Target Encoding Without Leakage（OOF 與平滑）

模型選擇

Grinsztajn, Oyallon & Varoquaux (2022), *Why do tree-based models still outperform deep learning on tabular data?*
Hollmann et al. (2025), *Accurate predictions on small data with a tabular foundation model*, Nature
TabPFN-2.5（作者自評，非獨立驗證）

問題拆解與 EDA

Umbrex, *Issue Tree Explained*（MECE 議題樹）
A Grammar of Hypotheses for Visualization, Data, and Analysis
John W. Tukey, *Exploratory Data Analysis* (1977)

完整連結見教科書 references.md。

術語表（一）問題定義・指標・驗證

預測時點 T0
做預測的那一刻；之前被觀察到的可用，之後的一律不能用

分析單位
資料表裡一列代表什麼（一位顧客？一筆訂單？）

目標變數
要預測的答案；門檻與時間窗要寫清楚

基準模型
完全不用動腦的預測方法，當作比較的底線

主指標
事先約定的唯一裁判，每次比較只看它

業務指標
把模型表現翻譯成決策者聽得懂的話

準確率
猜對的比例；少見事件時會騙人

Precision@K
排名最前面的 K 筆裡，有多少真的是

提升度 Lift
比隨便亂挑好幾倍

PR-AUC
門檻從嚴到鬆的精確率–召回率曲線下面積

召回率
所有真的是的裡面，抓到多少

訓練／驗證／保留集
課本／模擬考／正式考試；保留集只看一次

交叉驗證
資料輪流切成幾份，輪流當驗證，看平均與穩定性

Fold（折）
交叉驗證裡的「一次考試」

K-fold
把資料隨機分成 K 份，輪流當驗證集

術語表（二）切分・洩漏・實驗管理

- **群組 K-fold**
  以群組為單位切分，同一群組整組放在同一邊
- **時間切分／擴張視窗**
  用過去預測未來；每次訓練從起點開始、多一段
- **滾動起點回測**
  站在過去某天，只用之前的資料預測接下來 h 期
- **季節性樸素預測**
  用上一個週期同一時間的值當預測
- **同 fold 配對比較**
  在同一次驗證上比較，看新做法是否每次都贏
- **過擬合差距**
  訓練分數減驗證分數；差距大＝在背答案
- **資料洩漏**
  訓練時用到上線時拿不到的資訊
- **時點正確**
  歷史統計只用 T0 前已被觀察到的資料
- **擾動測試**
  竄改未來的資料，看特徵會不會跟著變
- **分布漂移**
  訓練時與上線時的資料長得不一樣
- **對抗驗證**
  訓練分辨器猜資料來自哪一期；猜得準＝有漂移
- **消融實驗**
  一次只加或拿掉一組特徵，看是誰的功勞
- **邊際價值**
  已有其他特徵時，再加它能多帶來多少進步
- **停止條件**
  開始前就寫好「做到什麼程度就停」
- **實驗紀錄**
  每次比較的特徵、模型、參數、每次考試的分數